

Gene Regulatory Network Construction: 方法・エビデンス・未解決課題に関するサーベイ

Paperclip–Codex survey workflow

2026 年 5 月 6 日

1 要旨

Gene regulatory network (GRN) construction は, transcription factor, target gene, cis-regulatory region, perturbation, および cellular context が gene-expression program をどのように形成するかを推定することを目的とする。本分野は, microarray 時代の reverse engineering と relevance network から, single-cell, multi-omic, perturbational, representation-learning workflow へと展開してきた。本稿は, Paperclip 検索と Codex built-in web search による triangulation を 3 ラウンド実施し, 2,283 件の deduplicated candidate から選定した 73 件の evidence card を統合する。中心的結論は, GRN construction は単一の algorithmic problem ではないという点である。むしろ, edge の意味が data に応じて変化する evidence-integration problem であり, co-expression, mutual information, conditional dependence, predictive importance, motif-supported TF-target relation, enhancer-mediated TF-region-gene circuit, dynamic influence, perturbation-supported transcriptional response または causal hypothesis は相互に同一視できない [28] [73] [41] [27] [1] [10] [15]。古典的手法は, 現在の tool に残る仮定を定義している点で依然として重要である。Bayesian network と dynamic Bayesian network は probabilistic structure を符号化し [17] [49], information-theoretic method は dependence を順位付けし [41] [16] [46] [8], regression と tree ensemble は regulator-to-target prediction を与え [4] [27] [24] [47], benchmark は data と metric への依存性が持続していることを示してきた [39] [40] [51]。近年の方向性は, chromatin accessibility, motif prior, curated regulatory resource, perturbation design, eQTL, spatial context, deep representation learning を加えている [10] [70] [9] [63] [22] [7] [19] [69] [33] [34] [53]。したがって, 高品質な GRN construction には, edge semantics の明示, context-aware prior, benchmark への慎重な態度, および科学的問いに適合した validation strategy が必要である。

図 1 は, 本サーベイの中心的な整理軸を示す。すなわち, GRN method は evidence strength, data richness, edge semantics, および横断的な validation constraint に基づいて解釈すべきで




図1 Evidence landscape for GRN construction.

ある。

2 序論

GRN は、gene expression に影響を与える分子間の regulatory relationship を表す model である。狭義の transcriptional GRN では、node は transcription factor と gene であり、directed edge は regulatory influence を意味する。しかし現在の workflow では、GRN および GRN-adjacent model は regulatory region, chromatin accessibility, perturbation, cell-type-specific activity state, さらに intercellular extension では ligand/receptor context を含むことが多い [28] [10] [15] [5]。この拡張は科学的には有用である一方、semantic ambiguity も生む。Pair-wise correlation から得られた edge, GENIE3 の feature-importance score, SCENIC regulon, SCENIC+ の enhancer-mediated eRegulon, Perturb-seq response はいずれも regulation を示唆し得るが、それぞれ異なる evidential commitment をもつ [27] [1] [10] [15]。

GRN construction の難しさは、基本的な inverse problem に由来する。Regulatory edge は通常、直接観測されない。多くの場合、expression variation, time ordering, chromatin state, sequence motif, curated knowledge, genetic variation, perturbational response, またはそれらの組合せから推定される。複数の時代の review は、この問題が high-dimensional, underde-

terminated, assumption-sensitive であり, experimental design に制約されることを強調している [28] [73] [43] [60] [61]。したがって, method の失敗は algorithm の弱さだけでなく, 利用可能な data が target network を復元する情報を十分に含まないことによっても生じ得る。Ensemble および inferability の分析は, recoverability が network と data regime によって変化することを明確に示した [40] [38]。

本分野の用語は, その歴史も反映している。古い文献では reverse engineering, gene-network inference, cellular network inference, relevance network, transcriptional regulatory network reconstruction といった表現が用いられた [60] [42] [6]。一方, single-cell および multi-omic の文献では, regulon, TF activity, enhancer-mediated GRN, eRegulon, TF-region-gene circuit, cell-state-specific GRN といった語が増えている [28] [1] [10] [66]。この多様性は単なる語彙の違いではない。Expression-only association graph から, molecular plausibility と context を符号化する multi-evidence model への移行を示している。本稿の目的は, 現在の inferred network の意味を規定し続ける古典的仮定を残しつつ, この移行を体系化することである。

3 方法と検索戦略

本レビューでは, run-specific で auditable な workflow を用いた。Paperclip search は, broad umbrella term, ユーザ指定語, historical reverse-engineering terminology, named algorithm, benchmark resource, single-cell GRN method, multi-omics, perturbational assay, eQTL method, spatial transcriptomics, non-TF regulatory layer, および critique term を対象とした。3 ラウンドの Paperclip search により, 144 個の raw CSV export と 5,191 行の raw row が得られた。DOI/title による merge と curated web integration の結果, 2,283 件の deduplicated candidate record が得られた。

Codex built-in web search は, evidence extraction の代替ではなく, triangulation と metadata verification の層として用いた。Web search は, regulon, eRegulon, enhancer-driven GRN, cell-type-specific network, single-cell multiome data, CausalBench, Airqtl, SpaGRN, scPRINT, GRNFormer, Meta-TGLink などに関する retrieval を拡張した。また publication status も補正し, 当初 adjacent preprint として記録されていた CausalBench は, 2025 年の Communications Biology 論文として更新された [9]。さらに, SCENIC+, LINGER, GEARS, Geneformer, scGPT, scPRINT, Airqtl, SpaGRN, Meta-TGLink の peer-reviewed metadata を確認した [10] [70] [54] [25] [11] [33] [34] [53] [48]。

Screening では, core, adjacent, context, out_of_scope の 4 tier を用いた。Preprint は preprint であることを理由に除外せず, 具体的な topical mismatch が確認されない限り, candidate paper は core, adjacent, または context に保持した。Deduplicated pool が 150 件を大きく超えたため, 本 run では minimum evidence threshold を超える 73 件の evidence card を作成した。Evidence card は, 本文の citation-bearing claim を支えるとともに, publication status,

evidence scope, method contribution, technical details, limitations, supported claims を記録している。また practical overview paper は、本稿の taxonomy が単なる歴史的整理ではなく実用的にも妥当であることを確認するために用いた [45]。

4 GRN Construction の分類体系

最も重要な区別は、association network と regulatory mechanism の区別である。Relevance network と WGCNA-style co-expression module は、exploratory biology, module discovery, hub-gene prioritization には有用であるが、一般に direct TF-target regulation ではなく undirected association を出力する [6] [72]。Graphical Gaussian model と partial-correlation method は、conditional dependence を推定することにより pairwise association を改善しようとし、C3NET のような conservative method は sparse high-confidence edge を優先する [58] [2]。これらの method は conditional-dependence structure を推定したり sparse high-confidence association を選択したりできるが、それ自体では biochemical direction や causality を確立しない。

Information-theoretic GRN inference は、co-expression と regulatory-network construction の間に持続的な橋を架けた。ARACNE は mutual information を推定し、data processing inequality により多くの indirect edge を pruning する。CLR は gene-specific background distribution に対して mutual information を正規化し、MRNET は maximum relevance/minimum redundancy feature selection を用いる。PIDC は multivariate single-cell dependence に information-theoretic reasoning を適用した [41] [16] [46] [8]。これらの強みは、simple linear correlation を超える dependence を捉え、genome-sized matrix に scale できる点にある。一方、限界も同じく重要である。Dependence は candidate relationship の evidence であって、direct regulatory edge の証明ではない。

Probabilistic and dynamical method は、より強い structural commitment を置く。Bayesian network は expression data に対する directed graphical model を導入し、dynamic Bayesian network は time slice 間の dependency を加えた [17] [49]。Time-series review は、temporal ordering が regulator と target の識別に役立ち得ることを示す一方、それが十分な sampling, synchronization, model adequacy のもとでのみ成立することも強調している [43] [60]。Directed partial correlation, dynGENIE3, SCODE, SINCERITIES, Scribe, TENET, SINGE は、dynamics, transfer entropy, Granger-style assumption, または pseudotime を GRN inference に導入する異なる方法を示している [26] [18] [44] [52] [71] [31] [13]。これらは static association method より強い temporal interpretation を支えるが、ordering, sampling density, hidden variable, identifiability に敏感である。

Regression, sparse feature selection, tree ensemble は、scale しやすく target-wise regulator ranking を出力するため、現在も中心的である。Inferelator は prior regulatory knowledge

と systems-biology data を統合し, TIGRESS は least-angle regression と stability selection を組み合わせる。GENIE3 は network inference を target-gene prediction with tree ensemble に分解し, GRNBoost2 は scalability を高める。さらに, NIMEFI と supervised/semi-supervised/unsupervised inference の比較は, ensemble feature-importance と learning setting がこの family を多様化していることを示し, Inferelator 3.0 は prior-informed regression を大規模 single-cell setting に適用した [4] [27] [24] [47] [37] [55] [65]。これらは実用的で benchmark-competitive なことが多いが, target expression を予測する regulator が必ずしもその expression の direct cause であるわけではない。したがって predictive edge semantics を明示する必要がある。

第 4 の family は prior と multi-modal evidence の統合である。PANDA は motif-derived TF-target prior, protein-protein interaction information, expression-derived co-regulation を message passing によって統合する [69]。SCENIC は co-expression module, motif enrichment, AUCell regulon-activity scoring を組み合わせ, single-cell regulatory program を要約する [1]。SCENIC+, scMEGA, LINGER, FigR, Pando は, chromatin accessibility, motif evidence, region-to-gene link, paired multiome data, または external atlas-scale data を用いて enhancer-mediated TF-region-gene relationship を推定する [10] [35] [70] [3] [68]。Cicero は single-cell chromatin accessibility から co-accessible DNA interaction を予測し, 関連する cis-regulatory layer を提供する [64]。これらの method は edge meaning を豊かにする一方, 新たな不確実性も導入する。Motif match は binding event そのものではなく, accessibility は必ずしも enhancer activity ではなく, peak-to-gene link にはしばしば曖昧性がある [7] [64]。

第 5 の family は, intervention, genetic variation, spatial context により causal interpretation へ近づくものである。初期の perturbational expression profiling は, intervention が passive observation を超えて genetic-network hypothesis を制約し得ることをすでに示していた [20]。その後, Perturb-seq と CROP-seq は targeted perturbation と single-cell transcriptome-wide readout を結び付け, TAP-seq と genome-scale Perturb-seq は experimental design space を拡張した [15] [12] [57] [21]。Perturbation-design study は, intervention label を明示的に用いることが inference を改善し得ること, また perturbation sample を ordinary observation として扱うべきではないことを示した [59]。CausalBench は single-cell perturbation data からの network inference に対する peer-reviewed large-scale benchmark を提供する [9]。FINDR と Airqtl は, eQTL または single-cell eQTL variation を, 適切な genetic-instrument と confounding assumptionのもとで causal information として用いる別系統の方法である [67] [33]。SpaGRN は spatial transcriptomics に GRN construction を拡張し, spatially constrained receptor-TF-target regulon を model 化する [34]。NicheNet は ligand を target-gene program に結び付ける intercellular communication prior により, GRN inference の境界領域を形成する [5]。

5 Method Family 間の比較エビデンス

歴史的展開は expression association から始まるが, expression association を direct regulation と混同してはならない。Butte and Kohane の relevance network と WGCNA は, gene cluster, module, hub を同定することにより expression data に network language を導入した [6] [72]。Graphical Gaussian approach と partial-correlation approach は, ほかの variable で conditioning することにより, より direct な association を識別できるかを問うた [58] [71]。これらは, 科学的目的が module discovery や candidate prioritization である場合には今なお有用な exploratory baseline であるが, TF-target edge や perturbation-supported edge よりも弱い biological claim しか支えない。

Information-theoretic method は, dependence structure に注目することで association-based inference を精緻化した。ARACNE, CLR, MRNET は pruning, normalization, feature-selection logic が異なるが, いずれも dense expression dependence が多くの false-positive または indirect candidate edge を生むという同じ問題に取り組む [41] [16] [46]。PIDC は, dropout と cellular heterogeneity が pairwise inference を複雑にする single-cell data に multivariate information measure を適用できることを示した [8]。概念的教訓は持続的である。Candidate-edge quality を改善することはできるが, edge の evidential category は変わらない。Temporal, motif, chromatin, genetic, perturbational information が加わらない限り, 結果は association evidence にとどまる。

Probabilistic and dynamical method は, edge の言語をより野心的なものにする。Bayesian network, dynamic Bayesian network, directed partial correlation, dynGENIE3, SINGE は, direction または temporal influence を語る方法を導入した [17] [49] [26] [71] [13]。ただし, 強い言語には強い assumption が伴う。Dynamic model は十分な sampling を必要とし, pseudotime method は信頼できる ordering を必要とし, Granger-style approach は predictive temporal precedence が対象 biological system で意味をもつことを必要とする [43] [31] [13]。このため dynamic GRN は, complete regulatory mechanism ではなく model-based causal hypothesis として解釈するのが妥当である。

Regression and tree-ensemble method は, scale し, 比較研究で良好に機能し, どの candidate regulator が各 target gene を説明するかという自然な生物学的問いに合致するため, 影響力を保っている。GENIE3 は benchmark reference point となり, SCENIC-style workflow の input にもなった [27] [1]。GRNBoost2 は target-wise regression logic を保ちながら practical scalability を改善した [47]。TIGRESS と Inferelator は, stability-selection tradition と prior-informed tradition を代表し [4] [24], Inferelator 3.0 はこの tradition が single-cell-scale setting でも継続していることを示す [65]。しかし regression edge は predictive relation である。Candidate regulator set が transcription factor に制限され, prior evidence が TF-target plausibility を

支え, chromatin や perturbation evidence と一致するとき, より biological interpretation が可能になる。

Benchmark は, 本分野の claim に繰り返し規律を与えてきた。DREAM と DREAM5 は, 単一の inference strategy がすべての network を支配するわけではなく, aggregate community prediction が individual method より robust になり得ることを示した [39] [40]。GeneNetWeaver と SERGIO は controlled in silico benchmarking を可能にしたが, 同時に simulator assumption が evaluation environment の一部になることも示した [56] [14]。BEELINE はこの比較論理を single-cell GRN inference に導入し, performance が input data, metric, gold-standard definition に依存することを示した [51]。Benchmark realism は, RegulonDB や TRRUST のような curated regulatory resource が incomplete, organism-specific, literature-biased であるため, 依然として困難である [63] [22]。したがって benchmark result は必要ではあるが, biological validity の十分条件ではない。

Single-cell data は機会とリスクの双方を変化させた。SCENIC の持続的貢献は edge list にとどまらず, regulon-activity abstraction にある。これは多数の candidate TF-target relation を cell-level activity program に変換し, cell state 間で比較可能にする [1]。PIDC, SINCERITIES, SCODE, Scribe, LEAP, TENET, SINGE は, single-cell variation を information theory, time stamp, pseudotime, または dynamics によって利用できることを示している [8] [18] [44] [52] [62] [31] [13]。同時に, single-cell sparsity, dropout, cell-type mixture, weak gold standard は unstable edge を生み得る [51] [29]。Single-cell resolution は GRN をより context-specific にするが, 自動的に causal にするわけではない。

Multi-omics は molecular plausibility を加えることで evidence standard を変える。Expression-only inference では, TF-target edge は TF expression が target expression を予測することを意味し得る。Enhancer-mediated multi-omic inference では, 同じ視覚的 edge が TF expression, chromatin accessibility, motif evidence, region-to-gene association, cell-type specificity を要約する場合がある [10] [35] [70] [3] [68]。JASPAR, DoRothEA, RegulonDB, TRRUST などの curated resource は, motif, regulon, prior interaction を提供し, search space を制約する [63] [22] [7] [19]。この豊かな evidence は interpretability を高めるが, assumption も増やす。厳密な報告では, edge が TF-gene, TF-region-gene, region-gene, regulon activity, または perturbation response のいずれであるかを明記すべきである。

Perturbational and genetic data は observational expression alone より強い causal leverage を提供するが, modeling を不要にするわけではない。Perturb-seq, CROP-seq, TAP-seq, genome-scale Perturb-seq は, intervention の measured transcriptomic consequence を与える [15] [12] [57] [21]。CellOracle は inferred network を in silico gene perturbation に用い, GEARS は novel multigene perturbation の transcriptional outcome を予測する [30] [54]。CausalBench は single-cell perturbation data からの network inference を評価し, Secilmis らは perturbation design に関する知識そのものが重要であることを示した [59] [9]。FINDR や Airqtl のような

genetic-variation method は、eQTL を通じて complementary causal leverage を提供する [67] [33]。ただし perturbation effect には、direct regulation, indirect cascade, feedback, cell-state shift, off-target effect が混在し得るため、intervention evidence は experimental design とともに解釈しなければならない。

Recent deep-learning and foundation-model method は、GRN inference の確立済み代替物というより、representation power を加えるものである。GEARS, Geneformer, scGPT, scFoundation は、large model または graph-enhanced model が perturbation response を予測し、biological representation を transfer し、large single-cell corpus を統合し得ることを示す [54] [25] [11] [23]。scPRINT は gene-network prediction のための large cell model としてより直接的に位置付けられ、GRNFormer と Meta-TGLink は graph transformer, graph autoencoding, few-shot meta-learning によって GRN inference を定式化する [53] [36] [48]。これらは、data が sparse で label が限られる場合に有望であるが、embedding, attention, predicted link は、古い network score と同様に evidential scrutiny を必要とする。

6 主な知見

第 1 に、GRN construction は evidence-strength spectrum として報告すべきである。Co-expression, relevance network, mutual information, conditional dependence, regression feature importance, motif-supported regulon, enhancer-mediated circuit, perturbation response, および instrument assumption のもとでの eQTL-supported causal inference は、この spectrum の異なる位置を占める [6] [58] [41] [27] [10] [15] [67]。これらの category を区別しない network diagram は、過剰解釈を招く。

第 2 に、method choice は data regime に従うべきである。Static bulk expression は co-expression, information-theoretic inference, regression, tree-based inference を支え得るが、causal direction には弱い [41] [27] [72]。Time-series または pseudotime data は、ordering と sampling が十分であれば dynamic hypothesis を支え得る [43] [26] [13]。scRNA-seq は cell-state-specific regulon analysis を可能にするが、sparsity と benchmark gold standard には注意を要する [1] [51] [29]。Paired scRNA-seq and scATAC-seq は enhancer-mediated GRN を支え、perturbational または eQTL data は、perturbation design または genetic-instrument assumption が明示される場合に、より強い causal hypothesis を支える [10] [70] [15] [59] [67] [33]。

第 3 に、prior はしばしば中心的であるが、不確実性を伴う evidence として扱うべきである。RegulonDB と TRRUST は curated regulatory interaction を提供し、JASPAR は transcription-factor binding profile を提供し、DoRothEA は TF-activity estimation と regulon use を支える [63] [22] [7] [19]。PANDA, SCENIC, SCENIC+, LINGER および関連 method は、prior-guided inference の価値を示している [1] [10] [70] [69]。しかし prior は incomplete,

literature-biased, organism-biased であり, 自動的に cell-state-specific ではない。暗黙の hard filtering よりも, confidence-aware な使用が望ましい。

第 4 に, evaluation は依然として中心的な bottleneck である。DREAM, DREAM5, GeneNetWeaver, SERGIO, BEELINE, CausalBench は, performance が network topology, simulator realism, perturbation coverage, gold-standard completeness, AUROC や AUPR などの metric に依存することを総体として示している [73] [39] [40] [56] [51] [14] [9]。問うべきなのは, 単にどの method が最良かではなく, 特定の edge meaning, data regime, validation target に対してどの method が適切かである。

第 5 に, 本分野は境界領域へ広がっている。miRNA-mediated network は, transcription-factor-centered GRN が唯一の regulatory network ではないことを想起させる [50]。NicheNet と SpaGRN は intracellular GRN を intercellular signaling と spatial tissue context に結び付ける [34] [5]。scPRINT, GRNFormer, Meta-TGLink は, representation-learning と graph-transfer component が GRN workflow に導入されつつある近年の例である [53] [36] [48]。ただし prediction や representation は experimentally validated regulation と同一ではないため, これらの方向性は慎重に統合すべきである。

7 エビデンス基盤の限界

本サーベイは広範で代表的であるが, 網羅的ではない。Landmark method, benchmark paper, resource paper, single-cell and multi-omic workflow, perturbational and eQTL approach, spatial/intercellular extension, selected recent deep-learning method を含む一方, すべての organism-specific application や incremental variant を列挙するものではない。この選択は一般的な survey としては妥当であるが, developmental, plant, microbial, cancer-specific, enhancer-biophysics の各文献は, 主として method と exemplar を通じて代表されることを意味する。

Evidence base には publication-status gradient もある。引用した landmark and modern method の大半は peer-reviewed である。Airqtl, SpaGRN, scPRINT, GRNFormer, Meta-TGLink のような 2025-2026 年の recent work は, 本 run の時点で web search と Paperclip retrieval により peer-reviewed または publisher-indexed version が確認されたため含めた [33] [34] [53] [36] [48]。ただし, これらの paper はまだ新しいため, 長期的な field impact に関する claim は意図的に抑制している。

最後に, GRN inference 自体に未解決の validation problem がある。Gold standard と prior は incomplete, organism-specific, literature-biased であり, 利用可能な motif, binding, expression, perturbation evidence によって制限される [63] [22] [7]。Perturbation data は強力であるが, direct effect と indirect effect が混在し得る [59]。Single-cell data には dropout, sparsity, cell-state heterogeneity が加わる [51] [29]。Multi-omic data には motif, accessibility, peak-to-gene

uncertainty が加わる [10] [64]。これらは本サーベイ固有の限界ではなく、本分野の中心的性質である。

8 未解決課題

第 1 の未解決課題は edge semantics である。将来の GRN tool は、各 edge が co-expression, mutual information, conditional dependence, predictive importance, motif-supported TF-target plausibility, enhancer-mediated TF-region-gene evidence, dynamic influence, perturbation-supported effect, instrument assumption のもとの eQTL-supported causal inference, または spatial/intercellular regulatory context のいずれを意味するかを報告すべきである [6] [41] [58] [27] [10] [15] [67] [34]。この情報がなければ、異なる method から得られる network は見た目には似ていても、科学的には異なるものになり得る。

第 2 の未解決課題は benchmark realism である。Synthetic benchmark は ground truth が既知であるため有用であるが、GeneNetWeaver と SERGIO は kinetics, topology, noise に関する assumption を含む [56] [14]。Curated regulatory resource は biological evidence を提供するが、incomplete で biased である [63] [22]。Perturbation benchmark はより強い intervention evidence を提供するが、perturbation design と response interpretation に依存する [59] [9]。成熟した evaluation ecosystem では、curated interaction, perturbation effect, chromatin evidence, time-series structure, uncertainty, task-specific metric を組み合わせる必要があるだろう。

第 3 の未解決課題は context transfer である。ある organism, cell type, disease state, assay platform, perturbation regime で inferred GRN が別の context に transfer できるとは限らない。LIONESS, Inferelator 3.0, LINGER, Airqtl, SpaGRN, Meta-TGLink は、sample-specific network, large single-cell dataset, atlas-scale prior, cell-state-specific eQTL, spatial regulon, few-shot transfer によって、この問題の一部に取り組んでいる [65] [32] [70] [33] [34] [48]。これらの例は、sample-specific network, scalable single-cell inference, atlas-scale prior, cell-state eQTL, spatial regulon, few-shot transfer を通じて context transfer を扱うが、まだ単一の settled transfer framework を提供しているわけではない。

第 4 の未解決課題は、prediction と explanation の関係である。Foundation model と graph neural network は、perturbation-response modeling, regulatory prediction, gene-network prediction, link prediction を支援し得る [54] [25] [11] [53] [36]。しかし expression をよく予測する model が、自動的に mechanistic GRN を与えるわけではない。今後は、representation を interpretable, falsifiable, experimentally testable な regulatory hypothesis に変換するための、より明確な protocol が必要である。

9 結論

GRN construction は, 単一の best inference algorithm を探す研究から, multi-evidence modeling problem へと成熟してきた。Classical association, probabilistic, regression, benchmark paper は, 現在の tool を形作る assumption と evaluation failure を定義しているため, 依然として不可欠である [17] [41] [27] [39] [40]。Single-cell and multi-omic method は context, regulon activity, enhancer-mediated evidence を加え, perturbational, eQTL, spatial, foundation-model approach は GRN が表現し得るものを拡張している [1] [10] [15] [33] [34] [53]。妥当な方向性は, 古い method を全面的に置き換えることではなく, edge semantics を明示し, evidence source を慎重に組み合わせ, 利用可能な最も強い experimental または curated evidence によって validation を行い, causal interpretation の限界を明記することである。

参考文献

- [1] Sara Aibar; Carmen Bravo Gonzalez-Blas; Thomas Moerman; Van Anh Huynh-Thu; Hana Imrichova; Gert Hulselmans; Florian Rambow; Jean-Christophe Marine; Pierre Geurts; Jan Aerts; Stein Aerts et al. Scenic: single-cell regulatory network inference and clustering. *Nature Methods*, 2017. doi: 10.1038/nmeth.4463. URL <https://www.nature.com/articles/nmeth.4463>. published peer-reviewed article.
- [2] Gokmen Altay and Frank Emmert-Streib. Inferring the conservative causal core of gene regulatory networks. *BMC Systems Biology*, 2010. doi: 10.1186/1752-0509-4-132. URL <https://doi.org/10.1186/1752-0509-4-132>. published peer-reviewed article.
- [3] Adam Kartha; Caleb J. B. et al. Figr: Functional inference of gene regulation using single-cell multi-omics. *Cell Genomics*, 2022. doi: 10.1016/j.xgen.2022.100166. URL <https://doi.org/10.1016/j.xgen.2022.100166>. published peer-reviewed article.
- [4] Richard Bonneau, David J. Reiss, Paul Shannon, Marc Facciotti, Leroy Hood, Nitin S. Baliga, and Vesteinn Thorsson. The inferelator: an algorithm for learning parsimonious regulatory networks from systems-biology data sets de novo. *Genome Biology*, 2006. doi: 10.1186/gb-2006-7-5-r36. URL <https://genomebiology.biomedcentral.com/articles/10.1186/gb-2006-7-5-r36>. published peer-reviewed article.
- [5] Robin Browaeys, Wouter Saelens, and Yvan Saeys. Nichenet: modeling intercellular communication by linking ligands to target genes. *Nature Methods*, 2020. doi: 10.1038/s41592-019-0667-5. URL <https://doi.org/10.1038/s41592-019-0667-5>. published peer-reviewed article.
- [6] Atul J. Butte and Isaac S. Kohane. Mutual information relevance networks: functional

- genomic clustering using pairwise entropy measurements. *Pacific Symposium on Bio-computing*, 2000. doi: 10.1142/9789814447331_0040. URL <https://pubmed.ncbi.nlm.nih.gov/10902190/>. published peer-reviewed article.
- [7] Castro-Mondragon et al. JaspAr 2024: 20th anniversary of the open-access database of transcription factor binding profiles. *Nucleic Acids Research*, 2024. doi: 10.1093/nar/gkad1059. URL <https://academic.oup.com/nar/article/52/D1/D174/7420101>. published peer-reviewed article.
- [8] Thalia E. Chan, Michael P. H. Stumpf, and Ann C. Babbie. Gene regulatory network inference from single-cell data using multivariate information measures. *Cell Systems*, 2017. doi: 10.1016/j.cels.2017.08.014. URL <https://pmc.ncbi.nlm.nih.gov/articles/PMC5624513/>. published peer-reviewed article.
- [9] Chevalley et al. A large-scale benchmark for network inference from single-cell perturbation data. *Communications Biology*, 2025. doi: 10.1038/s42003-025-07764-y. URL <https://doi.org/10.1038/s42003-025-07764-y>. published peer-reviewed article; earlier arXiv preprint located.
- [10] Carmen Bravo Gonzalez-Blas; Stijn De Winter; Gert Hulselmans; Nikolaus Hecker; Vlad Matetovici; Valerie Christiaens et al. Scenic+: single-cell multiomic inference of enhancers and gene regulatory networks. *Nature Methods*, 2023. doi: 10.1038/s41592-023-01938-4. URL <https://www.nature.com/articles/s41592-023-01938-4>. published peer-reviewed article.
- [11] Haotian Cui et al. scgpt: toward building a foundation model for single-cell multi-omics using generative ai. *Nature Methods*, 2024. doi: 10.1038/s41592-024-02201-0. URL <https://www.nature.com/articles/s41592-024-02201-0>. published peer-reviewed article.
- [12] Paul Datlinger, Andre F. Rendeiro, Christoph Schmidl, Thomas Krausgruber, Peter Traxler, Johanna Klughammer, Linda C. Schuster, Amelie Kuchler, Donat Alpar, and Christoph Bock. Pooled crispr screening with single-cell transcriptome readout. *Nature Methods*, 2017. doi: 10.1038/nmeth.4177. URL <https://pubmed.ncbi.nlm.nih.gov/28099430/>. published peer-reviewed article.
- [13] Atul Deshpande, Li-Fang Chu, Ron Stewart, and Anthony Gitter. Network inference with granger causality ensembles on single-cell transcriptomics. *Cell Reports*, 2022. doi: 10.1016/j.celrep.2022.110333. URL <https://pmc.ncbi.nlm.nih.gov/articles/PMC9093087/>. published peer-reviewed article.
- [14] Payam Dibaeinia and Saurabh Sinha. Sergio: A single-cell expression simulator guided by gene regulatory networks. *Cell Systems*, 2020. doi: 10.1016/j.cels.2020.08.003. URL <https://pmc.ncbi.nlm.nih.gov/articles/PMC7530147/>. published peer-reviewed ar-

ticle.

- [15] Atray Dixit, Oren Parnas, Biyu Li, Jenny Chen, Charles P. Fulco, Livnat Jerby-Arnon, Nemanja Marjanovic, Danielle Dionne, Tyler Burks, Britt Adamson, Thomas M. Norman, Eric Lander, Jonathan Weissman, Nir Friedman, and Aviv Regev. Perturb-seq: Dissecting molecular circuits with scalable single-cell rna profiling of pooled genetic screens. *Cell*, 2016. doi: 10.1016/j.cell.2016.11.038. URL <https://www.ncbi.nlm.nih.gov/bioproject/354362>. published peer-reviewed article.
- [16] Jeremiah J. Faith, Boris Hayete, Joshua T. Thaden, Ilaria Mogno, Jamey Wierzbowski, Guillaume Cottarel, Simon Kasif, James J. Collins, and Timothy S. Gardner. Large-scale mapping and validation of escherichia coli transcriptional regulation from a compendium of expression profiles. *PLoS Biology*, 2007. doi: 10.1371/journal.pbio.0050008. URL <https://journals.plos.org/plosbiology/article?id=10.1371/journal.pbio.0050008>. published peer-reviewed article.
- [17] Nir Friedman, Michal Linial, Iftach Nachman, and Dana Peer. Using bayesian networks to analyze expression data. *Journal of Computational Biology*, 2000. doi: 10.1089/106652700750050961. URL <https://doi.org/10.1089/106652700750050961>. published peer-reviewed article.
- [18] Nguyen Phong Papili Gao, S. M. M. Ud-Dean, Olivier Gandrillon, and Rudiyanto Gunawan. Sincerities: inferring gene regulatory networks from time-stamped single cell transcriptional expression profiles. *Bioinformatics*, 2018. doi: 10.1093/bioinformatics/btx575. URL <https://academic.oup.com/bioinformatics/article/34/2/258/4158033>. published peer-reviewed article.
- [19] Garcia-Alonso et al. Benchmark and integration of resources for the estimation of human transcription factor activities. *Genome Research*, 2019. doi: 10.1101/gr.240663.118. URL <https://saezlab.github.io/dorothea/index.html>. published peer-reviewed article.
- [20] Timothy S. Gardner, Diego di Bernardo, David Lorenz, and James J. Collins. Inferring genetic networks and identifying compound mode of action via expression profiling. *Science*, 2003. doi: 10.1126/science.1081900. URL <https://doi.org/10.1126/science.1081900>. published peer-reviewed article.
- [21] Joseph M. Replogle; Reuben A. Saunders; Angela N. Pogson; Jeffrey A. Hussmann; Alex Lenail; Arjun Guna et al. Mapping information-rich genotype-phenotype landscapes with genome-scale perturb-seq. *Cell*, 2022. doi: 10.1016/j.cell.2022.05.013. URL <https://pubmed.ncbi.nlm.nih.gov/35688146/>. published peer-reviewed article.
- [22] Han et al. Trustr: a reference database of human transcriptional regulatory interactions. *Scientific Reports*, 2015. doi: 10.1038/srep11432. URL <https://www.nature.com/articles/srep11432>. published peer-reviewed article.

- [23] Hao et al. Large-scale foundation model on single-cell transcriptomics. *Nature Methods*, 2024. doi: 10.1038/s41592-024-02305-7. URL <https://www.nature.com/articles/s41592-024-02305-7>. published peer-reviewed article.
- [24] Anne-Claire Haury, Fantine Mordelet, Paola Vera-Licona, and Jean-Philippe Vert. Tigrass: Trustful inference of gene regulation using stability selection. *BMC Systems Biology*, 2012. doi: 10.1186/1752-0509-6-145. URL <https://bmcsystbiol.biomedcentral.com/articles/10.1186/1752-0509-6-145>. published peer-reviewed article.
- [25] Christina V. Theodoris; Ling Xiao; Anant Chopra; Mark D. Chaffin; Ziad R. Al Sayed; Matthew C. Hill et al. Transfer learning enables predictions in network biology. *Nature*, 2023. doi: 10.1038/s41586-023-06139-9. URL <https://www.nature.com/articles/s41586-023-06139-9>. published peer-reviewed article.
- [26] Van Anh Huynh-Thu and Pierre Geurts. dyngenie3: dynamical genie3 for the inference of gene networks from time series expression data. *Scientific Reports*, 2018. doi: 10.1038/s41598-018-21715-0. URL <https://www.nature.com/articles/s41598-018-21715-0>. published peer-reviewed article.
- [27] Van Anh Huynh-Thu, Alexandre Irrthum, Louis Wehenkel, and Pierre Geurts. Inferring regulatory networks from expression data using tree-based methods. *PLoS ONE*, 2010. doi: 10.1371/journal.pone.0012776. URL <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0012776>. published peer-reviewed article.
- [28] Pau Badia i Mompel, Lorna Wessels, Sophia Muller-Dott, Remi Trimbou, Ricardo O. Ramirez Flores, Ricard Argelaguet, and Julio Saez-Rodriguez. Gene regulatory network inference in the era of single-cell multi-omics. *Nature Reviews Genetics*, 2023. doi: 10.1038/s41576-023-00618-5. URL <https://www.nature.com/articles/s41576-023-00618-5>. published peer-reviewed article.
- [29] Christopher A. Jackson et al. Evaluating methods of inferring gene regulatory networks highlights their lack of performance for single cell gene expression data. *BMC Bioinformatics*, 2018. doi: 10.1186/s12859-018-2217-z. URL <https://bmcbioinformatics.biomedcentral.com/articles/10.1186/s12859-018-2217-z>. published peer-reviewed article.
- [30] Kamimoto et al. Dissecting cell identity via network inference and in silico gene perturbation. *Nature*, 2023. doi: 10.1038/s41586-022-05688-9. URL <https://www.nature.com/articles/s41586-022-05688-9>. published peer-reviewed article.
- [31] Dylan Kim et al. Tenet: gene network reconstruction using transfer entropy reveals key regulatory factors from single cell transcriptomic data. *Nucleic Acids Research*, 2021. doi: 10.1093/nar/gkaa1014. URL <https://doi.org/10.1093/nar/gkaa1014>. published peer-reviewed article.

- [32] Marieke Lydia Kuijjer et al. Single-sample network inference with lioness. *iScience*, 2019. doi: 10.1016/j.isci.2019.03.021. URL <https://doi.org/10.1016/j.isci.2019.03.021>. published peer-reviewed article.
- [33] Kexin Li et al. Airqtl dissects cell state-specific causal gene regulatory networks with efficient single-cell eqtl mapping. *Nature Communications*, 2025. doi: 10.1038/s41467-025-66214-9. URL <https://www.nature.com/articles/s41467-025-66214-9>. published peer-reviewed article.
- [34] Yao Li, Xiaobin Liu, Lidong Guo, Kai Han, Shuangfang Fang, Xinjiang Wan, Xun Xu, Guangyi Fan, and Mengyang Xu. Spagrn: Investigating spatially informed regulatory paths for spatially resolved transcriptomics data. *Cell Systems*, 2025. doi: 10.1016/j.cels.2025.101243. URL <https://doi.org/10.1016/j.cels.2025.101243>. published peer-reviewed article.
- [35] Zhijian Li, James S. Nagai, Christoph Kuppe, Rafael Kramann, and Ivan G. Costa. scmega: single-cell multi-omic enhancer-based gene regulatory network inference. *Bioinformatics Advances*, 2023. doi: 10.1093/bioadv/vbad003. URL <https://pmc.ncbi.nlm.nih.gov/articles/PMC9853317/>. published peer-reviewed article.
- [36] Kazi M. and collaborators. Grnformer: accurate gene regulatory network inference using graph transformer. *Bioinformatics*, 2026. doi: 10.1093/bioinformatics/btag144. URL <https://academic.oup.com/bioinformatics/article/42/4/btag144/8540455>. published peer-reviewed article.
- [37] Stefan R. Maetschke, Piyush B. Madhamshettiwar, Melissa J. Davis, and Mark A. Ragan. Supervised, semi-supervised and unsupervised inference of gene regulatory networks. *Briefings in Bioinformatics*, 2014. doi: 10.1093/bib/bbt034. URL <https://pmc.ncbi.nlm.nih.gov/articles/PMC3956069/>. published peer-reviewed article.
- [38] Marbach et al. Ensemble inference and inferability of gene regulatory networks. *PLoS ONE*, 2014. doi: 10.1371/journal.pone.0103812. URL <https://doi.org/10.1371/journal.pone.0103812>. published peer-reviewed article.
- [39] Daniel Marbach, Robert J. Prill, Thomas Schaffter, Claudio Mattiussi, Dario Floreano, and Gustavo Stolovitzky. Revealing strengths and weaknesses of methods for gene network inference. *PNAS*, 2010. doi: 10.1073/pnas.0913357107. URL <https://pubmed.ncbi.nlm.nih.gov/20308593/>. published peer-reviewed article.
- [40] Daniel Marbach, James C. Costello, Robert Kuffner, Nicole M. Vega, Robert J. Prill, Diogo M. Camacho, Kyle R. Allison, DREAM5 Consortium, Manolis Kellis, James J. Collins, and Gustavo Stolovitzky. Wisdom of crowds for robust gene network inference. *Nature Methods*, 2012. doi: 10.1038/nmeth.2016. URL <https://pmc.ncbi.nlm.nih.gov/articles/PMC3512113/>. published peer-reviewed article.

- [41] Adam A. Margolin, Ilya Nemenman, Katia Basso, Chris Wiggins, Gustavo Stolovitzky, Riccardo Dalla Favera, and Andrea Califano. Aracne: An algorithm for the reconstruction of gene regulatory networks in a mammalian cellular context. *BMC Bioinformatics*, 2006. doi: 10.1186/1471-2105-7-S1-S7. URL <https://pmc.ncbi.nlm.nih.gov/articles/PMC1810318/>. published peer-reviewed article.
- [42] Florian Markowetz and Rainer Spang. Inferring cellular networks - a review. *BMC Bioinformatics*, 2007. doi: 10.1186/1471-2105-8-S6-S5. URL <https://bmcbioinformatics.biomedcentral.com/articles/10.1186/1471-2105-8-S6-S5>. published peer-reviewed article.
- [43] Malvina Marku et al. From time-series transcriptomics to gene regulatory networks: A review on inference methods. *PLOS Computational Biology*, 2023. doi: 10.1371/journal.pcbi.1011254. URL <https://doi.org/10.1371/journal.pcbi.1011254>. published peer-reviewed article.
- [44] Hirotaka Matsumoto, Hisanori Kiryu, Chikara Furusawa, Minoru S. H. Ko, Shigeru B. H. Ko, Norio Gouda, Tetsutaro Hayashi, and Itoshi Nikaido. Scode: an efficient regulatory network inference algorithm from single-cell rna-seq during differentiation. *Bioinformatics*, 2017. doi: 10.1093/bioinformatics/btx194. URL <https://academic.oup.com/bioinformatics/article/33/15/2314/3100331>. published peer-reviewed article.
- [45] Mercatelli, Scalambra, Triboli, Ray, and Giorgi. Gene regulatory network inference resources: A practical overview. *BBA - Gene Regulatory Mechanisms*, 2020. doi: 10.1016/j.bbagr.2019.194430. URL <https://www.sciencedirect.com/science/article/abs/pii/S1874939919300410>. published peer-reviewed article.
- [46] Patrick E. Meyer, Frederic Lafitte, and Gianluca Bontempi. Information-theoretic inference of large transcriptional regulatory networks. *BMC Bioinformatics*, 2008. doi: 10.1186/1471-2105-9-461. URL <https://pmc.ncbi.nlm.nih.gov/articles/PMC2630331/>. published peer-reviewed article.
- [47] Thomas Moerman, Sara Aibar Santos, Carmen Bravo Gonzalez-Blas, Jana Simm, Yves Moreau, Jan Aerts, and Stein Aerts. Grnboost2 and arboreto: efficient and scalable inference of gene regulatory networks. *Bioinformatics*, 2019. doi: 10.1093/bioinformatics/bty916. URL <https://academic.oup.com/bioinformatics/article/35/12/2159/5184284>. published peer-reviewed article.
- [48] Weiming Yu; Zhuobin Chen; Yaohua Hu; Jing Qin; Le Ou-Yang et al. Structure-enhanced graph meta learning for few-shot gene regulatory network inference. *Genome Biology*, 2025. doi: 10.1186/s13059-025-03860-8. URL <https://genomebiology.biomedcentral.com/articles/10.1186/s13059-025-03860-8>. published peer-reviewed article.

- [49] Blaise Perrin, Liva Ralaivola, Aurelien Mazurie, Sebastien Bottani, Jean Mallet, and Florence d Alche Buc. Gene networks inference using dynamic bayesian networks. *Bioinformatics*, 2003. doi: 10.1093/bioinformatics/btg1071. URL <https://doi.org/10.1093/bioinformatics/btg1071>. published peer-reviewed article.
- [50] Inna P. Plaisier et al. Overview of computational approaches for inference of microrna-mediated and gene regulatory networks. *Methods in Molecular Biology*, 2013. doi: 10.1007/978-1-62703-514-9_14. URL https://doi.org/10.1007/978-1-62703-514-9_14. published peer-reviewed article.
- [51] Aditya Pratapa, Amogh P. Jaliha, Jeffrey N. Law, Aditya Bharadwaj, and T. M. Murali. Benchmarking algorithms for gene regulatory network inference from single-cell transcriptomic data. *Nature Methods*, 2020. doi: 10.1038/s41592-019-0690-6. URL <https://www.nature.com/articles/s41592-019-0690-6>. published peer-reviewed article.
- [52] Xiaojie Qiu et al. Inferring causal gene regulatory networks from coupled single-cell expression dynamics using scribe. *Cell Systems*, 2020. doi: 10.1016/j.cels.2020.02.003. URL <https://pubmed.ncbi.nlm.nih.gov/32135093/>. published peer-reviewed article.
- [53] Cédric Reuter et al. scsprint: pre-training on 50 million cells allows robust gene network predictions. *Nature Communications*, 2025. doi: 10.1038/s41467-025-58699-1. URL <https://www.nature.com/articles/s41467-025-58699-1>. published peer-reviewed article.
- [54] Yusuf Roohani, Kexin Huang, and Jure Leskovec. Predicting transcriptional outcomes of novel multigene perturbations with gears. *Nature Biotechnology*, 2024. doi: 10.1038/s41587-023-01905-6. URL <https://www.nature.com/articles/s41587-023-01905-6>. published peer-reviewed article.
- [55] Joeri Ruyssinck, Van Anh Huynh-Thu, Pierre Geurts, Tom Dhaene, Piet Demeester, and Yvan Saeys. Nimefi: Gene regulatory network inference using multiple ensemble feature importance algorithms. *PLoS ONE*, 2014. doi: 10.1371/journal.pone.0092709. URL <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0092709>. published peer-reviewed article.
- [56] Thomas Schaffter, Daniel Marbach, and Dario Floreano. Genenetweaver: in silico benchmark generation and performance profiling of network inference methods. *Bioinformatics*, 2011. doi: 10.1093/bioinformatics/btr373. URL <https://academic.oup.com/bioinformatics/article/27/16/2263/254752>. published peer-reviewed article.
- [57] Daniel Schraivogel et al. Targeted perturb-seq enables genome-scale genetic screens in single cells. *Nature Methods*, 2020. doi: 10.1038/s41592-020-0837-5. URL <https://www.nature.com/articles/s41592-020-0837-5>. published peer-reviewed article.

- [58] Juliane Schäfer and Korbinian Strimmer. An empirical bayes approach to inferring large-scale gene association networks. *Bioinformatics*, 2005. doi: 10.1093/bioinformatics/bti062. URL <https://doi.org/10.1093/bioinformatics/bti062>. published peer-reviewed article.
- [59] Deniz Secilmis et al. Knowledge of the perturbation design is essential for accurate gene regulatory network inference. *Scientific Reports*, 2022. doi: 10.1038/s41598-022-19005-x. URL <https://doi.org/10.1038/s41598-022-19005-x>. published peer-reviewed article.
- [60] Chung S. Sima, Jing Hua, and Sunghoon Jung. Inference of gene regulatory networks using time-series data: A survey. *Current Genomics*, 2009. doi: 10.2174/138920209789177610. URL <https://pmc.ncbi.nlm.nih.gov/articles/PMC2766792/>. published peer-reviewed article.
- [61] Riet De Smet and Kathleen Marchal. Advantages and limitations of current network inference methods. *Nature Reviews Microbiology*, 2010. doi: 10.1038/nrmicro2419. URL <https://pubmed.ncbi.nlm.nih.gov/20805835/>. published peer-reviewed article.
- [62] Aaron T. Specht and Jun Li. Leap: constructing gene co-expression networks for single-cell rna-sequencing data using pseudotime ordering. *Bioinformatics*, 2017. doi: 10.1093/bioinformatics/btw729. URL <https://academic.oup.com/bioinformatics/article/33/5/764/2557687>. published peer-reviewed article.
- [63] Tierrafria et al. Regulondb v12.0: a comprehensive resource of transcriptional regulation in escherichia coli k-12. *Nucleic Acids Research*, 2024. doi: 10.1093/nar/gkad1072. URL <https://pmc.ncbi.nlm.nih.gov/articles/PMC10767902/>. published peer-reviewed article.
- [64] Hannah A. Pliner; Jay Shendure; Cole Trapnell et al. Cicero predicts cis-regulatory dna interactions from single-cell chromatin accessibility data. *Molecular Cell*, 2018. doi: 10.1016/j.molcel.2018.06.044. URL <https://doi.org/10.1016/j.molcel.2018.06.044>. published peer-reviewed article.
- [65] Claudia Skok Gibbs; Christopher A. Jackson; Giuseppe-Antonio Saldi; Andreas Tjarnberg; Aashna Shah; Aaron Watters; Nicholas De Veaux et al. High-performance single-cell gene regulatory network inference at scale: the inferelator 3.0. *Bioinformatics*, 2022. doi: 10.1093/bioinformatics/btac117. URL <https://pmc.ncbi.nlm.nih.gov/articles/PMC9048651/>. published peer-reviewed article.
- [66] Wang et al. Gene regulatory network reconstruction: harnessing the power of single-cell multi-omic data. *npj Systems Biology and Applications*, 2023. doi: 10.1038/s41540-023-00312-6. URL <https://www.nature.com/articles/s41540-023-00312-6>. published peer-reviewed article.

- [67] Lingfei Wang and Tom Michoel. Efficient and accurate causal inference with hidden confounders from genome-transcriptome variation data. *PLoS Computational Biology*, 2017. doi: 10.1371/journal.pcbi.1005703. URL <https://doi.org/10.1371/journal.pcbi.1005703>. published peer-reviewed article.
- [68] Jonas S. Fleck; Sara M. Jansen; Dominik Wollny et al. Inferring and perturbing cell fate regulomes in human brain organoids. *Nature*, 2023. doi: 10.1038/s41586-022-05279-8. URL <https://www.nature.com/articles/s41586-022-05279-8>. published peer-reviewed article.
- [69] Kimberly Glass; Curtis Huttenhower; John Quackenbush; Guo-Cheng Yuan et al. Passing messages between biological networks to refine predicted interactions. *PLoS ONE*, 2013. doi: 10.1371/journal.pone.0064832. URL <https://doi.org/10.1371/journal.pone.0064832>. published peer-reviewed article.
- [70] Qiuyue Yuan and Zhana Duren. Inferring gene regulatory networks from single-cell multiome data using atlas-scale external data. *Nature Biotechnology*, 2025. doi: 10.1038/s41587-024-02182-7. URL <https://www.nature.com/articles/s41587-024-02182-7>. published peer-reviewed article.
- [71] Yinyin Yuan, Chang-Tsun Li, and Oliver Windram. Directed partial correlation: Inferring large-scale gene regulatory network through induced topology disruptions. *PLoS ONE*, 2011. doi: 10.1371/journal.pone.0016835. URL <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0016835>. published peer-reviewed article.
- [72] Bin Zhang and Steve Horvath. A general framework for weighted gene co-expression network analysis. *Statistical Applications in Genetics and Molecular Biology*, 2005. doi: 10.2202/1544-6115.1128. URL <https://doi.org/10.2202/1544-6115.1128>. published peer-reviewed article.
- [73] Mengyuan Zhao et al. A comprehensive overview and critical evaluation of gene regulatory network inference technologies. *Briefings in Bioinformatics*, 2021. doi: 10.1093/bib/bbab009. URL <https://academic.oup.com/bib/article/22/5/bbab009/6128842>. published peer-reviewed article.