

医療・ヘルスケアにおける大規模言語モデル：能力、評価、ワークフロー、ガバナンスのサーベイ

Paperclip-Codex survey workflow

2026 年 5 月 6 日

1 要旨

大規模言語モデル (LLM) は、biomedical text mining のためのモデルから、汎用的な臨床支援、オープンな医療特化モデル、検索拡張生成 (RAG) システム、マルチモーダルエージェント、診療文書作成、患者メッセージ、治験マッチング、意思決定支援のためのワークフロー技術へと展開している。本稿は、4 回の Paperclip 検索と Codex built-in web search によって得られた 1,020 件の候補から構築した 103 件の構造化エビデンスカードを統合する。文献からは三つの同時進行する傾向が読み取れる。第一に、ドメイン適応は依然として重要である。Biomedical encoders、clinical-note models、structured-EHR transformers、EHR-scale models は、それぞれ異なる医療データ分布を対象とする [39] [18] [92] [85] [40] [62]。第二に、初期の ChatGPT-on-USMLE 研究と Med-PaLM から HealthBench、MedHELM、MedXpertQA、MedBench、GMAI-MMBench、LiveMedBench に至るまで、ベンチマーク性能は急速に向上している。ただし、試験得点、静的 QA、VQA スコア、ループリック評価はいずれも臨床アウトカムの代替指標にとどまる [69] [1] [49] [100] [35] [76] [44] [7] [91]。第三に、短期的にもっとも臨床実装へ近いのは、人間がレビューする支援的ワークフローである。検索に基づく回答と治験マッチング、模擬診断対話、患者メッセージ下書き、ambient documentation、放射線レポート下書き、administrative extraction には、増えつつあるがタスク固有のエビデンスが存在する [95] [82] [30] [72] [9] [47] [79]。本稿の結論は、医療 LLM を孤立したテキスト生成器ではなく、社会技術的な臨床システムとして評価すべきであるという点にある。実装には、タスク固有の検証、人間による監督、不確実性と公平性の評価、敵対的テスト、プライバシー保護、ライフサイクル監視、intended use に対応したガバナンスが必要である [61] [57] [13] [55] [66] [73] [54]。

この図は、本サーベイの構成原理を要約している。すなわち、biomedical and clinical foundations が general and medical LLMs を支え、grounding and agents がモデルを reviewed clinical workflows に接続し、clinical deployment は evaluation evidence、safety and equity controls、governance、lifecycle monitoring に依存する。




図 1 医療・ヘルスケアにおける LLM を、層状の臨床システムとして概観した模式図。

2 序論

医療は言語に強く依存する領域である。診断は問診から始まり、治療計画は診療記録とガイドラインに記述され、治験適格性は eligibility criteria の解釈に左右され、患者は書かれた説明を通じて医療情報を求める。このため、LLM は医療に自然に適合するように見える。しかし、その適合性こそが危険の源泉でもある。流暢で説得的な文は、事実誤認、臨床文脈の欠落、不確実性の過小評価、バイアス、安全でない行動を覆い隠しうる。したがって、現在の文献は、LLM が自律的医療に十分であることの証拠ではなく、能力が急速に伸長していることの証拠として読む必要がある [56] [4] [46]。

この領域は ChatGPT から始まったわけではない。Biomedical and clinical NLP では、以前からドメインコーパスの重要性が示されていた。BioBERT と PubMedBERT は biomedical literature にエンコーダを適応し、ClinicalBERT と GatorTron は clinical notes と EHR narratives を対象とした [39] [23] [18] [92]。BioGPT は biomedical text generation and mining における生成型事前学習の有用性を示した [48]。これらのモデルは主として情報抽出、予測、ベンチマーク QA を扱い、開かれた臨床対話を直接対象としたものではなかった。それでも、医学用語、エビデンス基準、データプライバシー、臨床ワークフローがドメイン固有である以上、一般的な言語能力だけでは不十分であるという本領域の中心的前提を確立した。

2022 年以降の展開では、instruction-following、チャットインターフェース、大規模な proprietary models、オープンな医療 LLM、マルチモーダルシステムが加わった。Med-PaLM と MultiMedQA は、複数のデータセットと、factuality、scientific consensus、harm、bias、help-

fulness に関する人間評価を組み合わせることで、医療 QA 評価を多次元化した [69]。GPT-4 は、医学的 fine-tuning なしでも USMLE 型問題や複雑な医学問題で高い性能を示しうることを示した [53]。Med-PaLM 2、HealthBench、MedHELM、MedXpertQA は、専門家水準の QA、開かれたループリック評価、より広いタスク集合、マルチモーダル専門推論へと評価を広げた [70] [1] [49] [100]。ただし、これらの研究が同時に明らかにしているのは、医療ベンチマークは進歩の測定には有用であっても、安全な臨床業務そのものではないという緊張関係である。

本稿は、どのモデルが高性能かだけでなく、どの種類のエビデンスがどの種類の主張を支えているのかを問う。MedQA で高得点のモデルであっても、検査・治療選択、逐次的な情報収集、現実的な EHR 操作には失敗しうる [33] [26]。患者メッセージや ambient scribe のシステムは業務負荷を軽減しうる一方で、文体、レビュー責任、note quality、well-being、公平性に関する新たな問題を生む [3] [72] [47] [79]。RAG や multimodal system は grounding を改善しうるが、検索された context が不十分である場合、医療誤情報が挙動を汚染する場合、または vision-language setting に prompt injection が到達する場合には失敗しうる [95] [90] [88] [17]。このため、本稿はモデル名のランキングではなく、機能的役割、エビデンスの種類、実装上のリスクを軸として構成する。

3 方法・検索戦略

本レビューは、scoping review の規律を取り入れた narrative survey として実施した。Paperclip 検索は 4 段階で行った。第 1 ラウンドでは、medical LLMs、ChatGPT/GPT-4、medical QA、biomedical and clinical language models、documentation、RAG、multimodality、privacy、fairness、safety、governance を含む 26 件の広範かつ焦点化されたクエリを用いた。第 2 ラウンドでは、AMIE、HealthBench、ambient scribes、patient portal messages、TrialGPT、Almanac、data poisoning、health equity、主要な multimodal/open medical systems を対象に 18 件のギャップ駆動型クエリを追加した。Web-search audit により欠落していたランドマークを特定し、MedHELM、MedXpertQA、NYUTron、clinical decision-making limitations、patient-inbox deployments、randomized diagnostic-reasoning trials、medical agents、AI co-scientist systems を対象とする第 3 ラウンドを実施した。さらに coverage auditor の指摘を受けて、第 4 ラウンドでは open-weight clinical models、中国語・多言語医療 LLM、structured-EHR foundation models、medical VQA/radiology benchmarks、EHR agents、ambient-scribe trials、hallucination/calibration benchmarks、privacy/de-identification、HIPAA de-identification guidance、benchmark contamination を重点的に検索した。

Codex built-in web search は、エビデンス抽出の代替ではなく、recall と検証の統合レイヤーとして用いた。具体的には、出版状況の確認、公式ガバナンス資料の追加、preprint の後続査読版の確認、Paperclip の full-text coverage が弱い可能性のあるランドマークの発見に用いた。例として、Med-PaLM と Med-PaLM 2 の Nature および Nature Medicine 版、AMIE の Nature

論文、TrialGPT の Nature Communications 版、WHO の large multimodal model guidance、FDA の AI/ML Software as a Medical Device 資料、NIST AI Risk Management Framework が含まれる [69] [70] [82] [50] [30] [57] [13] [55]。

正規化タイトルによる重複排除と発見ソース間の統合の結果、候補表には 1,020 件のレコードが含まれた。スクリーニングでは core、adjacent、context、out_of_scope の 4 階層を用いた。Preprint status は記録したが、除外理由としては用いなかった。最終エビデンス基盤は 103 件の構造化エビデンスカードから構成される。候補数が 150 件を超えたため、50 件以上の evidence cards というプロジェクト基準を上回り、coverage audit 後に open models、multimodal systems、EHR modeling、deployment evidence、safety の代表性を高めるため拡張した。本稿で引用する文献およびガイダンス文書は、すべて evidence cards に対応している。

4 タクソノミー

4.1 1. Biomedical and Clinical Language-Model Foundations

第一の層はドメイン適応である。BioBERT と PubMedBERT などの biomedical encoders は、biomedical text での事前学習が biomedical NLP を改善することを示した [39] [18]。ClinicalBERT と GatorTron は clinical-note modeling が独自の問題であることを示し、GatorTron は大規模な deidentified clinical text corpora によって clinical language modeling を拡張した [23] [92]。BioGPT と GatorTronGPT は、この系譜を biomedical literature と clinical text に対する GPT-style generation へ拡張した [48] [93]。別系統として、BEHRT、Med-BERT、CEHR-BERT、EHRSHOT/CLMBR、NYUTron などの structured-EHR lineage があり、これらは開かれた対話ではなく、コード化または記録ベースの患者履歴を予測に用いる [85] [40] [62] [60] [25]。技術的教訓は、medical LLM が単一の技術カテゴリではないという点である。文献モデル、note models、structured-EHR models、チャット支援、予測エンコーダは、データ、目的関数、リスクが異なる。

4.2 2. Medical QA and Benchmark-Centered Systems

医療 QA ベンチマークは、能力向上をもっとも可視化しやすい領域である。MedQA、PubMedQA、MedMCQA は、それぞれ専門職試験知識、biomedical abstract reasoning、広範な医学多肢選択問題を測るため中心的なデータセットとなった [29] [28] [58]。初期の ChatGPT-on-USMLE 研究は、汎用会話モデルが医学的 fine-tuning なしに一部の医師国家試験水準へ接近しう一方、科目や難度で性能が変動することを示し、医療教育上の含意を可視化した [35] [14]。MultiMedQA は consumer health questions と人間評価を組み合わせ、Med-PaLM を性能面だけでなく評価設計上のランドマークとした [69]。GPT-4 は、closed general-purpose model が医療特化学習なしに一部の医学ベンチマークで強い性能を示しうること示した [53]。

HealthBench、MedHELM、MedXpertQA、CMExam、MedBench、LiveMedBench などの新しいベンチマークは、飽和、言語カバレッジ、contamination、ecological validity への懸念に応え、開かれた会話、広いタスク集合、専門推論、非英語の医学試験、現実的臨床ケース、時間的分離を取り込んでいる [1] [49] [100] [44] [7] [91]。

これらの限界は、ベンチマークが無意味であるという点ではなく、限られた問いにしか答えないという点にある。多肢選択 accuracy は、人工的に制約された選択肢の中での認識能力を測る。PubMedQA は abstract-grounded biomedical reasoning を測るが、ベッドサイド医療を測るものではない [28]。HealthBench は医師ループリックによって現実性を高めるが、それでも患者アウトカム研究ではなく応答品質ベンチマークである [1]。LiveMedBench は、継続的に更新される症例と時間的分離により、contamination 問題を明示する [91]。AgentClinic と MedAgentBench は相補的な点を示す。静的な医学知識を逐次的な臨床相互作用や EHR 操作へ移すと、タスク性能の低下や invalid actions が可視化される [67] [26]。

4.3 3. Open and Domain-Specialized Medical LLMs

オープンな医療モデルは、再現性、ローカル検証、監査可能性、protected health information を closed systems に自由に送れない環境に関する実践的懸念に応答する。MedAlpaca、PMC-LLaMA、ChatDoctor、MEDITRON、MedGemma、BioMistral、Med42、Clinical Camel、HuaTuo、HuatuoGPT、DISC-MedLLM、Apollo は、biomedical corpora での continued pretraining、guidelines/textbooks の導入、instruction tuning、dialogue-based knowledge encoding、doctor-data alignment、多言語学習、parameter-efficient または full-parameter fine-tuning などの戦略を示す [8] [20] [86] [41] [77] [36] [11] [80] [83] [96] [75] [84]。MEDITRON は、70B parameters まで open medical pretraining を拡張し、医療ガイドラインを高価値データとして位置づけた点で特に重要である [8]。BioMistral と Med42-v2 は、open ecosystem が初期の LLaMA derivatives を越え、Mistral-based および Llama-3-based clinical model suites へ拡張したことを示す [36] [12]。

ただし、オープン性は安全性の保証ではない。Open models は、データ品質の限界、benchmark contamination、benchmark-centered evaluation、言語・地理的ギャップ、deployment validation の不足に直面しうる [8] [20] [86] [77] [91]。一部の open medical LLM は preprint または technical report にとどまり、多くは臨床アウトカムではなく exam、QA、consultation benchmarks で評価されている [36] [11] [12] [96] [75]。したがって、open medical LLMs は、直ちに臨床実装可能な製品ではなく、再現可能な研究とローカル検証のためのインフラとして位置づけるべきである [63]。

4.4 4. Grounded, Retrieval-Augmented, and Tool-Using Systems

医療リスクへの第二の技術的応答は grounding である。Almanac は、LLM 回答を検索された臨床情報源に接続し、unsupported generation と比較して factuality と grounding が改善したと報告した [95]。より広い RAG ベンチマークは、この方向性が必要であると同時に不十分でもあることを示す。検索は medical QA を改善しうるが、不適切または不完全な context は生成を誤らせるため、システムは sufficiency、integration、robustness の観点から評価される必要がある [90]。Med-PaLM 2 の retrieval and refinement methods も同じ原理を反映している。難しい臨床問題では、parametric recall だけではなく、外部エビデンスと claim checking が必要になる [70]。

Grounding はワークフローシステムにも拡張されている。TrialGPT は、検索、criterion-level eligibility prediction、trial ranking を組み合わせ、患者と治験をマッチングする。pilot user study ではスクリーニング時間の短縮が報告される一方、専門家監督は維持された [30]。PRISM は、実際の oncology EHR に基づく task-specific models が、semantic trial matching においてより大規模な汎用モデルと競合しうることを示す [68]。MDAgents、AgentClinic、MedAgentBench、AI co-scientist のような multi-agent and tool-using approaches は、医療および biomedical workflows の agentic な方向性を示している [34] [67] [26] [16]。これらは memory と action を外部化する一方で、irrelevant retrieval、poisoning、adversarial prompting、invalid EHR actions、multimodal prompt injection を system-level risks として評価する必要を生む [90] [2] [89] [17] [26]。

4.5 5. Clinical Reasoning and Diagnostic Assistance

診断支援はもっとも注目されやすく、同時にもっとも過大評価されやすい応用である。GPT-4 は、複雑な診断チャレンジや USMLE 型タスクで高性能を示したが、これらは curated cases や exam materials に基づく [53] [32]。AMIE は静的 QA を越え、診断対話に最適化されたシステムとして、模擬 text-chat OSCE-style encounters において primary care physicians と比較して高い性能を示した [82]。AMIE の differential diagnosis 研究も、難しい NEJM case reports における医師の鑑別診断リストを LLM が改善しうる可能性を示している [50]。

しかし、臨床推論は診断名を挙げることに尽きない。Nature Medicine の臨床意思決定に関するエビデンスは、LLM が知識豊富にみえる場合でも、検査や治療選択では不十分に振る舞いうることを示している [33]。診断推論に対する LLM の影響を検証した randomized trial は、重要な human-factor layer を追加する。単独モデルの正答率から、臨床医の利益を推定することはできない。ツールの効果は、訓練、プロンプト、信頼、ワークフローに依存するためである [15]。したがって、防御可能な結論は、置換ではなく支援可能性である。

4.6 6. Communication, Documentation, and Administrative Workflows

コミュニケーションと文書化は、臨床医のレビューを自然に組み込むため、もっとも近い実装領域である。JAMA Internal Medicine の研究では、公共フォーラム上の患者質問に対する ChatGPT 応答が、医師フォーラム回答よりも高い品質と共感性で評価者に好まれた。しかし、EHR context を欠く public-forum setting は臨床的妥当性を制限する [3]。患者メッセージ研究は実際のワークフローに近づいており、LLM による返信下書きや patient inbox deployment は実現可能性を示す一方で、良い患者返信を定義する安定した参照基準の不足も明らかにしている [71] [72]。

文書化ツールも有望であるが、リスクを伴う。Ambient scribes は文書作成負担を軽減し、盲検評価で許容可能な note quality を生成しうるが、quality assurance、billing implications、downstream safety、clinician review は依然として課題である [64]。新しい randomized and pragmatic trials は、ambient AI scribes が note text quality だけでなく、clinical-practice implementation、work exhaustion、professional fulfillment、utilization、documentation burden の観点から評価され始めたことを示す [47] [79]。退院サマリー生成は、長い入院経過を handoff documents に圧縮できるため魅力的であるが、情報欠落は安全性に直結しうる [37]。Administrative coding も同じ構図を示す。汎用 LLM は ICD extraction に苦戦しうる一方、domain-specific tuning によって clinical text variation への頑健性が改善する場合がある [5] [45]。これらは単なる事務作業ではなく、ケアの継続性、償還、品質測定、患者理解を左右する。

4.7 7. Multimodal and Generalist Medical AI

医療データは本質的にマルチモーダルである。画像、波形、検査値、レポート、ゲノム、縦断的記録が相互に関係する。LLaVA-Med、Med-Flamingo、Med-Gemini、BiomedGPT は、LLM-style interfaces を biomedical images と mixed-modality reasoning に拡張する試みである [42] [51] [81] [98]。データ層も同様に重要である。MIMIC-CXR、CheXpert、VQA-RAD、PathVQA、SLAKE、PMC-VQA、OmniMedVQA は、medical VLM と VQA evaluation ecosystem の主要な基盤である [31] [24] [38] [21] [43] [97] [22]。RadFM、CheXagent、CXR-LLaVA、HuatuoGPT-Vision、GMAI-MMBench は、radiology foundation models、chest-X-ray report assistance、open CXR LVLMS、medical visual instruction tuning、広範な multimodal evaluation へとこの生態系を拡張している [87] [9] [74] [10] [76]。

Generalist medical AI の視点は、foundation models が将来的に isolated classifiers ではなく、柔軟でマルチモーダルかつ複数タスクにまたがる医療システムを支える可能性を論じる [52]。Scoping review も、text-only LLM から documentation、decision support、report generation、discovery のための multimodal AI への移行を指摘している [6]。Multimodality はエビデンス水準を引き上げる。Image understanding benchmarks は完全な臨床画像ワークフ

ローではなく簡略化された VQA pairs に依存しう一方、radiology report-assistance studies には reader workflow と quality assessment が必要である [38] [9]。Long-context and structured EHR tasks には temporal structure と local validation が必要である [85] [60]。Multimodal prompt injection は仮説上の問題ではない。Oncology vision-language systems は、画像に埋め込まれた悪意ある指示に脆弱でありうる [17]。したがって、multimodal medical LLMs は、一括りの能力向上としてではなく、modality、task、setting、user role ごとに評価される必要がある。

4.8 8. Safety, Equity, Security, Ethics, and Governance

安全性エビデンスはすべての群に横断する。Targeted misinformation attacks は、通常のベンチマーク性能を保ったまま、医療事実に関するモデル挙動を汚染しうることを示す [88]。Data-poisoning studies は、低レベルの悪意ある医療誤情報が training corpora に混入するだけで、標的医療トピックに影響しうることを示している [2]。Adversarial prompting と prompt injection は、medical QA、patient-summary、vision-language settings にリスクを拡張する [89] [17]。MedHallBench と MedHallu のような hallucination-specific benchmarks は、medical factuality、abstention、error scoring のためのドメイン固有テストを追加する [99] [59]。Privacy work は別の安全性層を加える。公式の HIPAA de-identification guidance は法的な de-identification routes と技術的匿名性を区別し、PHI benchmarks、annotation frameworks、clinical-note privacy studies は、LLM-enabled workflows において leakage、over-redaction、membership inference、re-identification を handoff boundaries で明示的に評価する必要があることを示す [54] [73] [78] [65] [27]。

公平性エビデンスも中心的である。Health-equity toolboxes と bias studies は、平均 accuracy が subgroup harms、stereotype reproduction、不公平な recommendations を覆い隠しうることを示す [61] [94]。倫理レビューは、clinician-facing と layperson-facing の利用を区別しつつ、privacy、misinformation、bias、accountability、human oversight を繰り返し強調している [19]。WHO、FDA、NIST のガバナンス文書は相補的な視点を提供する。WHO は large multimodal models を stakeholder participation と post-release audit を必要とする health-system technologies として位置づけ、FDA は AI/ML medical software の lifecycle と premarket considerations を強調し、NIST は汎用的な risk-management structure を提示する [57] [13] [55]。これらは性能エビデンスではないが、性能エビデンスだけでは定義できない義務を明確にする。

5 比較エビデンス

群	代表的エビデンス	主な貢献	主な限界
Biomedical/clinical foundations	BioBERT, PubMedBERT, ClinicalBERT, BioGPT, GatorTron, GatorTronGPT, EHRSHOT, BEHRT, Med-BERT, CEHR-BERT, NYUTron [39] [23] [18] [48] [92] [93] [85] [40] [62] [60] [25]	Domain-specific corpora と structured patient timelines が biomedical, clinical-note, EHR prediction tasks を改善する。	主にベンチマークまたは後ろ向き予測エビデンスであり、臨床対話や実装検証ではない。
Medical QA and evaluation	MedQA, PubMedQA, MedMCQA, USMLE studies, Med-PaLM, GPT-4, HealthBench, MedHELM, MedXpertQA, CMExam, MedBench, LiveMedBench [29] [28] [58] [35] [14] [69] [53] [1] [49] [100] [44] [7] [91]	標準化および live benchmarks により、能力向上、言語カバレッジ、contamination risk、新たな評価次元を測定する。	静的、多肢選択、VQA-style、model-graded の場合、臨床ケアの proxy にとどまる。
Open medical models	MEDITRON, MedAlpaca, PMC-LLaMA, ChatDoctor, MedGemma, BioMistral, Med42, Clinical Camel, HuaTuo/HuatuoGPT, DISC-MedLLM, Apollo [8] [20] [86] [41] [77] [36] [11] [12] [80] [83] [96] [75] [84] [63]	再現性、inspectability、local validation options を高める。	オープン性は data quality、contamination、安全性、language coverage、regulatory validation を解決しない。
Grounded/workflow systems	Almanac, RAG benchmark, TrialGPT, PRISM, MDAgents, AgentClinic, MedAgentBench [95] [90] [30] [68] [34] [67] [26]	Retrieval, ranking, tools, agents により出力の traceability と workflow specificity を高める。	Retrieval errors, invalid actions, adversarial prompting, prompt injection が system risks となる。
Clinical reasoning	GPT-4 challenges, AMIE, clinical decision critique, diagnostic RCT [32] [82] [50] [33] [15]	制御されたシミュレーションと一部の clinician workflows において診断支援可能性を示す。	日常臨床での利益と安全性には、前向きかつ workflow-aware な研究が必要である。
Communication/documentation	Patient Q&A, patient inbox drafts, ambient scribes, discharge summaries, coding [3] [72] [64] [47] [79] [37] [5] [45]	人間がレビューする近接ワークフローで負担軽減と下書き支援が可能である。	Quality assurance, readability, coding errors, downstream safety, accountability が未解決である。

群	代表的エビデンス	主な貢献	主な限界
Multimodal/generalist AI	LLaVA-Med, Med-Flamingo, Med-Gemini, BiomedGPT, MIMIC-CXR, CheXpert, VQA-RAD, OmniMedVQA, RadFM, CheXagent, HuatuoGPT-Vision, GMAI-MMBench [42] [51] [81] [98] [31] [24] [38] [22] [87] [9] [10] [76]	Text-only assistance から実際の医療データ複雑性と広範な medical visual evaluation へ近づく。	Modality-specific validation、security、clinical integration は能力主張に追いついていない。
Safety/governance	Misinformation, poisoning, prompt injection, hallucination, PHI/privacy, equity, ethics, WHO/FDA/NIST/HHS [88] [2] [89] [17] [99] [59] [73] [78] [54] [65] [27] [61] [19] [57] [13] [55]	Security、equity、privacy、lifecycle、regulatory controls の必要性を明確化する。	Mitigation evidence は risk identification と benchmark evaluation より未成熟である。

6 主な知見

第一に、医療 LLM の能力は、臨床エビデンスの質よりも速く向上している。Med-PaLM、Med-PaLM 2、GPT-4、HealthBench、および新しい benchmark suites は、medical QA、health-response quality、task coverage における大きな進歩を示す [69] [70] [53] [1] [49] [100]。しかし、医療応用の体系的評価文献は、多くの研究が accuracy metrics と限られた real patient data に依存し、公平性や頑健性の評価が相対的に乏しいことを示している [4]。LiveMedBench はさらに、static benchmark contamination と temporal mismatch を評価上の脅威として強調する [91]。したがって、この分野には、拡大するベンチマーク生態系を成熟した臨床エビデンス基盤と取り違える危険がある。

第二に、ドメイン特化は有用であるが決定的ではない。Biomedical、clinical-note、structured-EHR pretraining は、biomedical literature、EHR language、longitudinal patient trajectories に依存するタスクで性能を改善する [48] [92] [93] [85] [40] [62] [60] [25]。Open medical LLMs は、curated guidelines、textbooks、PubMed/PMC articles、medical instruction data、doctor dialogues、多言語コーパスによって open-model medical-task performance を改善する [8] [20] [86] [36] [96] [84]。一方で、GPT-4 は、医学特化学習を受けていない汎用 frontier model でも、一部の医療ベンチマークで高い性能を示しうること示した [53]。実践上の設計問題は、general か medical かという二分法ではなく、base capability、domain data、grounding、local

validation、oversight のどの組み合わせがタスクに適合するかである。

第三に、短期的にもっとも強い実装根拠をもつのは、人間がレビューする支援である。TrialGPT と PRISM は治験スクリーニングを支援し、patient-message systems は返信を下書きし、ambient scribes は診療記録を下書きし、CheXagent-like radiology systems はレポートを下書きし、coding systems は制約された administrative extraction を支援する [30] [68] [72] [64] [9] [45]。Randomized and pragmatic ambient-scribe trials は、workflow and well-being outcomes をエビデンス基盤へ加えつつある [47] [79]。これらの応用は、人間が出力を確認、修正、却下できるワークフローに LLM を挿入するため魅力的である。リスクは、時間圧、automation bias、労働削減への組織的圧力の下で、レビューが実質を失うことである。

第四に、診断支援と agentic assistance は有望であるが、まだ決着していない。AMIE の模擬診断対話と differential diagnosis 研究は技術的に印象的である [82] [50]。GPT-4 と Med-PaLM 2 は、ベンチマークおよび challenge conditions の下で強い医療推論能力を示す [70] [53] [32]。しかし、臨床意思決定研究、randomized clinician trials、AgentClinic、MedAgentBench は、より難しい問いが、LLM がもっともらしい診断名を出せるかではなく、臨床医の推論を改善し、必要な情報を求め、適切な検査と治療選択を支え、現実的ワークフローで valid actions を実行できるかであることを示している [33] [15] [67] [26]。

第五に、安全性は免責的な注意書きではなく、工学およびガバナンスの問題として扱う必要がある。Hallucination は failure mode の一つにすぎない。Poisoned data、targeted misinformation、adversarial prompting、prompt injection、不公平な recommendations、PHI leakage、re-identification risk、regulatory scope の不明確さは、平均ベンチマーク性能が高く見える場合でも危害を生みうる [88] [2] [89] [17] [61] [94] [73] [54] [65] [27] [13]。安全な医療 LLM システムには、data provenance、retrieval provenance、output monitoring、equity testing、cybersecurity controls、clinical escalation paths、user training、lifecycle governance が必要である [57] [13] [55]。

7 エビデンス基盤の限界

文献は不均衡である。Medical QA はベンチマーク化しやすいため過剰に表れている一方、現実の臨床ワークフローは研究しにくい。多くの研究は、時間とともに挙動が変化する proprietary models を用いており、厳密な再現が難しい [53]。多くの open models は preprint または technical reports であり、方法の網羅には有用だが、臨床エビデンスとしては弱い [8] [20] [77] [36] [12]。Prospective and randomized evidence はまだ比較的少ないが、patient-inbox、diagnostic reasoning、ambient-scribe、一部の workflow studies では蓄積が始まっている [72] [15] [47] [79]。

データの代表性も持続的な限界である。GatorTron、EHRSHOT/CLMBR、CEHR-BERT、NYUTron のような EHR-trained models は強力であるが、特定の医療機関、coding systems、

documentation cultures に結びついている [92] [85] [60] [25]。MedQA、MedMCQA、CMExam、MedBench、XMedBench-style multilingual evaluations は、試験環境、言語、国別の医学教育文脈を反映している [29] [58] [44] [7] [84]。HealthBench は physician involvement を含むが、どのベンチマークも、症例、rubrics、言語、良い助言の定義に関する選択を内包する [1]。Equity tools は危害を表面化させるが、実装後の公平なアウトカムを証明するものではない [61]。

最後に、本サーベイ自体も、分野の進展速度による限界をもつ。本稿は広範な検索と evidence-card workflow に基づくが、登録済みの systematic review や meta-analysis ではない。焦点は、model families、tasks、risks を横断する技術的統合にある。検索日以降の新たなモデルリリースは、本稿で構築した枠組みに従って解釈すべきである。すなわち、能力主張を受け入れる前に、task、data、user、evaluation type、deployment context、risk controls を特定する必要がある。

8 未解決課題

1. 前向き臨床検証。患者アウトカム、臨床医の workload、diagnostic accuracy、communication quality、equity、unintended consequences を測定する prospective、pragmatic、randomized studies がさらに必要である。
1. 静的 QA を超える評価。ベンチマークは、sequential decisions、incomplete information、investigation and treatment choices、multimodal data、interactive EHR actions、contamination control、abstention または hallucination scoring を含むべきである [33] [67] [26] [99] [59] [91]。
1. Grounding と provenance。RAG と tools は、answer accuracy だけでなく、source quality、retrieval sufficiency、irrelevant context、robustness、provenance、failure cases を報告すべきである [95] [90]。
1. Human-AI interaction。LLM access が現実的な訓練とワークフロー条件の下で臨床医の推論を改善するのか、review interfaces が documentation、well-being、decision quality にどう影響するのかについてのエビデンスが必要である [15] [47] [79]。
1. Equity と global validity。評価には、demographic subgroup harms、language access、multilingual benchmarks、local health-system constraints を含めるべきである [61] [57] [44] [7] [84]。
1. Security、privacy、lifecycle monitoring。医療 LLM には、misinformation、poisoning、prompt injection、hallucination、PHI leakage、re-identification、invalid actions、benchmark contamination への防御と、intended use に対応した lifecycle risk management が必要である [88] [2] [89] [17] [26] [99] [59] [73] [54] [65] [27] [91] [55]。

1. 規制上の明確性。診断、triage、治療、患者固有の recommendations を生成するシステムは、文書化支援から medical device-like functions へ移行しうる。したがって、intended use と risk によって governance を決定すべきである [13]。

9 結論

医療・ヘルスケアにおける LLM は、エビデンス段階の異なる技術群として理解するのが適切である。Biomedical、clinical-note、structured-EHR language models はドメインデータの価値を示し、Med-PaLM、GPT-4、HealthBench、MedHELM、MedXpertQA、LiveMedBench、global benchmarks は急速な進歩と持続的な評価限界を示す。Open medical models は再現可能な実験基盤を提供するが、自動的な臨床実装可能性を意味しない。AMIE、TrialGPT、patient messaging、ambient scribes、radiology VLMs、EHR agents は支援的ワークフローの可能性を示し、安全性・ガバナンス研究は能力だけでは不十分であることを示す。したがって中心的結論は条件付きである。LLM は、タスク範囲が明示され、エビデンスが intended use に対応し、人間の監督が実質的であり、privacy と equity が評価され、de-identification が完全な匿名性と誤認されず、lifecycle governance が実装に組み込まれている場合に、医療において有用となりうる。これらの条件を欠く場合、洗練された医療言語は臨床資産ではなく、リスク増幅器となりうる。

参考文献

- [1] Arora et al. Healthbench: Evaluating large language models towards improved human health. *OpenAI*, 2025. URL <https://openai.com/index/healthbench/preprint/benchmark>.
- [2] Awan et al. Medical large language models are vulnerable to data-poisoning attacks. *Nature Medicine*, 2025. doi: 10.1038/s41591-024-03445-1. URL <https://www.nature.com/articles/s41591-024-03445-1>. published.
- [3] Ayers et al. Comparing physician and artificial intelligence chatbot responses to patient questions posted to a public social media forum. *JAMA Internal Medicine*, 2023. doi: 10.1001/jamainternmed.2023.1838. URL <https://jamanetwork.com/journals/jamainternalmedicine/fullarticle/2804309>. published.
- [4] Bedi et al. Testing and evaluation of health care applications of large language models: A systematic review. *JAMA Network Open*, 2024. doi: 10.1001/jamanetworkopen.2024.22768. URL <https://pubmed.ncbi.nlm.nih.gov/39405325/>. published.
- [5] Boyle et al. Benchmarking large language models for extraction of international classification of diseases codes from clinical documentation. *medRxiv*, 2024. doi: 10.1101/2024.04.29.24306573. URL <https://pubmed.ncbi.nlm.nih.gov/39606395/>.

- preprint/PubMed record.
- [6] Buess et al. From large language models to multimodal ai: a scoping review on the potential of generative ai in medicine. *Biomedical Engineering Letters*, 2025. URL <https://pmc.ncbi.nlm.nih.gov/articles/PMC12411359/>. published.
 - [7] Cai et al. Medbench: A large-scale chinese benchmark for evaluating medical large language models. *arXiv*, 2023. URL <https://arxiv.org/abs/2312.12806>. preprint only.
 - [8] Chen et al. Meditron-70b: Scaling medical pretraining for large language models. *arXiv*, 2023. URL <https://arxiv.org/abs/2311.16079>. preprint only.
 - [9] Chen et al. A vision-language foundation model to enhance efficiency of chest x-ray interpretation. *arXiv*, 2024. doi: 10.48550/arXiv.2401.12208. URL <https://arxiv.org/abs/2401.12208>. preprint only.
 - [10] Chen et al. Huatuoqpt-vision, towards injecting medical visual knowledge into multimodal llms at scale. *ACL/arXiv*, 2024. URL <https://arxiv.org/abs/2406.19280>. published conference version found.
 - [11] Christophe et al. Med42 – evaluating fine-tuning strategies for medical llms: Full-parameter vs. parameter-efficient approaches. *arXiv*, 2024. URL <https://arxiv.org/abs/2404.14779>. preprint only.
 - [12] Christophe et al. Med42-v2: A suite of clinical llms. *arXiv*, 2024. URL <https://arxiv.org/abs/2408.06142>. preprint only.
 - [13] U.S. Food and Drug Administration. Artificial intelligence in software as a medical device. *FDA*, 2026. URL <https://www.fda.gov/medical-devices/software-medical-device-samd/artificial-intelligence-software-medical-device>. current regulatory page.
 - [14] Gilson et al. How does chatgpt perform on the united states medical licensing examination (usmle)? the implications of large language models for medical education and knowledge assessment. *JMIR Medical Education*, 2023. URL <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC9947764/>. published.
 - [15] Goh et al. Large language model influence on diagnostic reasoning: A randomized clinical trial. *JAMA Network Open*, 2024. doi: 10.1001/jamanetworkopen.2024.40969. URL <https://jamanetwork.com/journals/jamanetworkopen/fullarticle/2825395>. published.
 - [16] Gottweis et al. Towards an ai co-scientist. *arXiv*, 2025. doi: <https://arxiv.org/abs/2502.18864>. URL [arx_2502.18864](https://arxiv.org/abs/2502.18864). preprint only.
 - [17] Greshake et al. Prompt injection attacks on vision language models in oncology. *Nature Communications*, 2025. doi: 10.1038/s41467-024-55631-x. URL <https://www.nature.com/articles/s41467-024-55631-x>.

- [com/articles/s41467-024-55631-x](https://www.nature.com/articles/s41467-024-55631-x). published.
- [18] Gu et al. Pubmedbert: Domain-specific language model pretraining for biomedical natural language processing. *ACL Anthology*, 2021. URL <https://aclanthology.org/2021.acl-long.182/>. published.
 - [19] Haltaufderheide and Ranisch. The ethics of chatgpt in medicine and health-care: a systematic review on large language models (llms). *npj Digital Medicine*, 2024. doi: 10.1038/s41746-024-01157-x. URL <https://www.nature.com/articles/s41746-024-01157-x>. published.
 - [20] Han et al. Medalpaca – an open-source collection of medical conversational ai models and training data. *arXiv*, 2023. URL <https://arxiv.org/abs/2304.08247>. preprint only.
 - [21] He et al. Pathvqa: 30000+ questions for medical visual question answering. *arXiv*, 2020. URL <https://arxiv.org/abs/2003.10286>. published/preprint.
 - [22] Hu et al. Omnimedvqa: A new large-scale comprehensive evaluation benchmark for medical lvlm. *CVPR*, 2024. URL https://openaccess.thecvf.com/content/CVPR2024/papers/Hu_OmniMedVQA_A_New_Large-Scale_Comprehensive_Evaluation_Benchmark_for_Medical_LVLm_CVPR_2024_paper.pdf. published.
 - [23] Huang, Altosaar, and Ranganath. Clinicalbert: Modeling clinical notes and predicting hospital readmission. *arXiv*, 2019. URL <https://arxiv.org/abs/1904.05342>. preprint only.
 - [24] Irvin et al. Chexpert: A large chest radiograph dataset with uncertainty labels and expert comparison. *AAAI*, 2019. URL <https://stanfordmlgroup.github.io/competitions/chexpert/>. published.
 - [25] Jiang et al. Health system-scale language models are all-purpose prediction engines. *Nature*, 2023. doi: 10.1038/s41586-023-06160-y. URL <https://www.nature.com/articles/s41586-023-06160-y>. published.
 - [26] Jiang et al. Medagentbench: A realistic virtual ehr environment to benchmark medical llm agents. *NEJM AI*, 2025. doi: 10.1056/AIdbp2500144. URL <https://stanfordmlgroup.github.io/projects/medagentbench/>. published in NEJM AI with arXiv/project materials.
 - [27] Jiang et al. Paradox of de-identification: A critique of hipaa safe harbour in the age of llms. *arXiv*, 2026. doi: 10.48550/arXiv.2602.08997. URL <https://arxiv.org/abs/2602.08997>. preprint only.
 - [28] Jin et al. Pubmedqa: A dataset for biomedical research question answering. *EMNLP-IJCNLP*, 2019. URL <https://arxiv.org/abs/1909.06146>. published.
 - [29] Jin et al. What disease does this patient have? a large-scale open domain question

- answering dataset from medical exams. *arXiv*, 2020. URL <https://arxiv.org/abs/2009.13081>. preprint/dataset.
- [30] Jin et al. Matching patients to clinical trials with large language models. *Nature Communications*, 2024. URL <https://pmc.ncbi.nlm.nih.gov/articles/PMC11574183/>. published.
- [31] Johnson et al. Mimic-cxr, a de-identified publicly available database of chest radiographs with free-text reports. *Scientific Data*, 2019. URL <https://physionet.org/content/mimic-cxr/>. published.
- [32] Kanjee et al. Accuracy of a generative artificial intelligence model in a complex diagnostic challenge. *JAMA*, 2023. doi: 10.1001/jama.2023.8288. URL <https://pubmed.ncbi.nlm.nih.gov/37318797/>. published.
- [33] Kanjee et al. Evaluation and mitigation of the limitations of large language models in clinical decision-making. *Nature Medicine*, 2024. doi: 10.1038/s41591-024-03097-1. URL <https://www.nature.com/articles/s41591-024-03097-1>. published.
- [34] Kim et al. Mdagents: An adaptive collaboration of llms for medical decision-making. *arXiv*, 2024. URL <https://arxiv.org/abs/2404.15155>. preprint only.
- [35] Kung et al. Performance of chatgpt on usmle: Potential for ai-assisted medical education using large language models. *PLOS Digital Health*, 2023. URL <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC9931230/>. published.
- [36] Labrak et al. Biomistral: A collection of open-source pretrained large language models for medical domains. *ACL Findings/arXiv*, 2024. URL <https://arxiv.org/abs/2402.10373>. published conference version found.
- [37] Larios et al. Physician- and large language model-generated hospital discharge summaries: A blinded, comparative quality and safety study. *medRxiv*, 2024. doi: 10.1101/2024.09.29.24314562. URL <https://www.medrxiv.org/content/10.1101/2024.09.29.24314562v1.full-text>. preprint only.
- [38] Lau et al. Vqa-rad: Visual question answering in radiology. *VQA-RAD*, 2018. URL <https://osf.io/89kps/>. published.
- [39] Lee et al. Biobert: a pre-trained biomedical language representation model for biomedical text mining. *Bioinformatics*, 2019. doi: 10.1093/bioinformatics/btz682. URL <https://doi.org/10.1093/bioinformatics/btz682>. published.
- [40] Li et al. Behrt: Transformer for electronic health records. *Scientific Reports*, 2020. URL <https://pmc.ncbi.nlm.nih.gov/articles/PMC7189231/>. published.
- [41] Li et al. Chatdoctor: A medical chat model fine-tuned on a large language model meta-ai (llama) using medical domain knowledge. *arXiv*, 2023. doi: <https://arxiv.org/abs/2303.14070>. preprint only.

- [42] Li et al. Llava-med: Training a large language-and-vision assistant for biomedicine in one day. *NeurIPS Datasets and Benchmarks*, 2023. URL <https://arxiv.org/abs/2306.00890>. published conference/preprint.
- [43] Liu et al. Slake: A semantically-labeled knowledge-enhanced dataset for medical visual question answering. *IEEE ISBI/arXiv*, 2021. URL <https://arxiv.org/abs/2102.09542>. published.
- [44] Liu et al. Benchmarking large language models on cmexam – a comprehensive chinese medical exam dataset. *arXiv*, 2023. URL <https://arxiv.org/abs/2306.03030>. preprint only.
- [45] Liu et al. Enhancing medical coding efficiency through domain-specific fine-tuned large language models. *npj Health Systems*, 2025. doi: 10.1038/s44401-025-00018-3. URL <https://www.nature.com/articles/s44401-025-00018-3>. published.
- [46] Liu et al. Current applications and challenges in large language models for patient care: a systematic review. *Communications Medicine*, 2025. doi: 10.1038/s43856-024-00717-2. URL <https://www.nature.com/articles/s43856-024-00717-2>. published.
- [47] Lukac et al. Ambient ai scribes in clinical practice: A randomized trial. *NEJM AI*, 2025. doi: 10.1056/AIoa2501000. URL <https://pubmed.ncbi.nlm.nih.gov/41497288/>. published.
- [48] Luo et al. Biogpt: Generative pre-trained transformer for biomedical text generation and mining. *Briefings in Bioinformatics*, 2022. doi: 10.1093/bib/bbac409. URL <https://arxiv.org/abs/2210.10341>. published.
- [49] Mahajan et al. Medhelm: Holistic evaluation of large language models for medical tasks. *arXiv*, 2025. URL <https://arxiv.org/abs/2505.23802>. preprint only.
- [50] McDuff et al. Towards accurate differential diagnosis with large language models. *Nature*, 2025. doi: 10.1038/s41586-025-08869-4. URL <https://www.nature.com/articles/s41586-025-08869-4>. published.
- [51] Moor et al. Med-flamingo: a multimodal medical few-shot learner. *arXiv*, 2023. URL <https://arxiv.org/abs/2307.15189>. preprint only.
- [52] Moor et al. Foundation models for generalist medical artificial intelligence. *Nature*, 2023. doi: 10.1038/s41586-023-05881-4. URL <https://www.nature.com/articles/s41586-023-05881-4>. published.
- [53] Nori et al. Capabilities of gpt-4 on medical challenge problems. *arXiv*, 2023. URL <https://arxiv.org/abs/2303.13375>. preprint only.
- [54] U.S. Department of Health and Office for Civil Rights Human Services. Guidance regarding methods for de-identification of protected health information in ac-

- cordance with the hipaa privacy rule. *HHS*, 2012. URL <https://www.hhs.gov/hipaa/for-professionals/special-topics/de-identification/index.html>. official guidance.
- [55] National Institute of Standards and Technology. Artificial intelligence risk management framework (ai rmf 1.0). *NIST*, 2023. URL <https://www.nist.gov/itl/ai-risk-management-framework>. official framework.
 - [56] Omiye et al. Large language models in medicine: the potentials and pitfalls. *Annals of Internal Medicine*, 2024. doi: 10.7326/M23-2772. URL <https://doi.org/10.7326/M23-2772>. published.
 - [57] World Health Organization. Ethics and governance of artificial intelligence for health: guidance on large multi-modal models. *WHO*, 2024. URL <https://iris.who.int/handle/10665/375579>. published guidance.
 - [58] Pal et al. Medmcqa : A large-scale multi-subject multi-choice dataset for medical domain question answering. *arXiv*, 2022. doi: <https://arxiv.org/abs/2203.14371>. URL [arx_2203.14371](https://arxiv.org/abs/2203.14371). published.
 - [59] Pandit et al. Medhallu: A comprehensive benchmark for detecting medical hallucinations in large language models. *arXiv*, 2025. doi: 10.48550/arXiv.2502.14302. URL <https://arxiv.org/abs/2502.14302>. preprint only.
 - [60] Pang et al. Cehr-bert: Incorporating temporal information from structured ehr data to improve prediction tasks. *arXiv*, 2021. URL <https://arxiv.org/abs/2111.08585>. preprint only.
 - [61] Pfohl et al. A toolbox for surfacing health equity harms and biases in large language models. *Nature Medicine*, 2024. doi: 10.1038/s41591-024-03258-2. URL <https://arxiv.org/abs/2403.12025>. published.
 - [62] Rasmy et al. Med-bert: pretrained contextualized embeddings on large-scale structured electronic health records for disease prediction. *npj Digital Medicine*, 2021. URL <https://www.nature.com/articles/s41746-021-00455-y>. published.
 - [63] Riedemann, Labonne, and Gilbert. The path forward for large language models in medicine is open. *npj Digital Medicine*, 2024. doi: 10.1038/s41746-024-01344-w. URL <https://www.nature.com/articles/s41746-024-01344-w>. published.
 - [64] Ripp et al. Assessing the quality of ai-generated clinical notes: validated evaluation of a large language model ambient scribe. *Frontiers Digital Health*, 2025. URL <https://pubmed.ncbi.nlm.nih.gov/41199808/>. published.
 - [65] Sarkar et al. De-identification is not enough: a comparison between de-identified and synthetic clinical notes. *Scientific Reports*, 2024. doi: 10.1038/s41598-024-81170-y. URL <https://www.nature.com/articles/s41598-024-81170-y>. published.

- [66] Savage et al. Probabilistic medical predictions of large language models. *npj Digital Medicine*, 2024. URL <https://www.broadinstitute.org/publications/broad1358571>. published.
- [67] Schmidgall et al. Agentclinic: a multimodal agent benchmark to evaluate ai in simulated clinical environments. *arXiv*, 2024. URL <https://arxiv.org/abs/2405.07960>. preprint only.
- [68] Shao et al. Prism: Patient records interpretation for semantic clinical trial matching using large language models. *PMC*, 2024. URL <https://pmc.ncbi.nlm.nih.gov/articles/PMC11519882/>. published/preprint version.
- [69] Singhal et al. Large language models encode clinical knowledge. *Nature*, 2023. doi: 10.1038/s41586-023-06291-2. URL <https://www.nature.com/articles/s41586-023-06291-2>. published.
- [70] Singhal et al. Toward expert-level medical question answering with large language models. *Nature Medicine*, 2025. doi: 10.1038/s41591-024-03423-7. URL <https://www.nature.com/articles/s41591-024-03423-7>. published.
- [71] Tai-Seale et al. The effect of using a large language model to respond to patient messages. *The Lancet Digital Health*, 2024. URL <https://pubmed.ncbi.nlm.nih.gov/38664108/>. published.
- [72] Tai-Seale et al. Artificial intelligence – generated draft replies to patient inbox messages. *JAMA Network Open*, 2024. doi: 10.1001/jamanetworkopen.2024.3201. URL <https://jamanetwork.com/journals/jamanetworkopen/fullarticle/2816494>. published.
- [73] ASQ-PHI team. Asq-phi: An adversarial synthetic data benchmark for clinical de-identification and search utility. *PMC*, 2026. URL <https://pmc.ncbi.nlm.nih.gov/articles/PMC12926592/>. published.
- [74] CXR-LLaVA team. Cxr-llava: a multimodal large language model for interpreting chest x-ray images. *European Radiology*, 2025. doi: 10.1007/s00330-024-11339-6. URL <https://pmc.ncbi.nlm.nih.gov/articles/PMC12166004/>. published.
- [75] DISC-MedLLM team. Disc-medllm: Bridging general large language models and real-world medical consultation. *arXiv*, 2023. URL <https://arxiv.org/abs/2308.14346>. preprint only.
- [76] GMAI-MMBench team. Gmai-mmbench: A comprehensive multimodal evaluation benchmark towards general medical ai. *NeurIPS Datasets and Benchmarks*, 2024. doi: 10.52202/079017-2992. URL https://proceedings.neurips.cc/paper_files/paper/2024/hash/ab7e02fd60e47e2a379d567f6b54f04e-Abstract-Datasets_and_Benchmarks_Track.html. published.

- [77] Google/MedGemma team. Medgemma technical report. *arXiv*, 2025. URL <https://arxiv.org/abs/2507.05201>. technical report/preprint.
- [78] Jiang/Yang team. Large language model empowered privacy-protected framework for phi annotation in clinical notes. *PubMed/arXiv*, 2025. URL <https://pubmed.ncbi.nlm.nih.gov/40775983/>. published PubMed-indexed source found.
- [79] Tai-Seale/Stanford team. A pragmatic randomized controlled trial of ambient artificial intelligence to improve health practitioner well-being. *NEJM AI*, 2025. doi: 10.1056/aioa2500945. URL <https://pubmed.ncbi.nlm.nih.gov/41625485/>. published.
- [80] Toma et al. Clinical camel: An open expert-level medical language model with dialogue-based knowledge encoding. *arXiv*, 2023. URL <https://arxiv.org/abs/2305.12031>. preprint only.
- [81] Tu et al. Capabilities of gemini models in medicine. *arXiv*, 2024. URL <https://arxiv.org/abs/2404.18416>. preprint only.
- [82] Tu et al. Towards conversational diagnostic artificial intelligence. *Nature*, 2025. doi: 10.1038/s41586-025-08866-7. URL <https://www.nature.com/articles/s41586-025-08866-7>. published.
- [83] Wang et al. Huatuo: Tuning llama model with chinese medical knowledge. *arXiv*, 2023. URL <https://arxiv.org/abs/2304.06975>. preprint only.
- [84] Wang et al. Apollo: A lightweight multilingual medical llm towards democratizing medical ai to 6b people. *arXiv*, 2024. URL <https://arxiv.org/abs/2403.03640>. preprint only.
- [85] Wornow et al. Ehrshot: An ehr benchmark for few-shot evaluation of foundation models. *arXiv*, 2023. URL <https://arxiv.org/abs/2307.02028>. preprint only.
- [86] Wu et al. Pmc-llama: Towards building open-source language models for medicine. *arXiv*, 2023. doi: <https://arxiv.org/abs/2304.14454>. preprint only.
- [87] Wu et al. Towards generalist foundation model for radiology by leveraging web-scale 2d&3d medical data. *Nature Communications*, 2025. doi: 10.1038/s41467-025-62385-7. URL <https://www.nature.com/articles/s41467-025-62385-7>. published.
- [88] Xie et al. Medical large language models are susceptible to targeted misinformation attacks. *npj Digital Medicine*, 2024. doi: 10.1038/s41746-024-01282-7. URL <https://www.nature.com/articles/s41746-024-01282-7>. published.
- [89] Xie et al. Adversarial attacks on large language models in medicine. *arXiv*, 2024. URL <https://arxiv.org/abs/2406.12259>. published/preprint version.
- [90] Xiong et al. Benchmarking retrieval-augmented generation for medicine. *arXiv*, 2024. URL <https://aclanthology.org/2024.findings-acl.372.pdf>. preprint only.
- [91] Yan et al. Livemedbench: A contamination-free medical benchmark for llms with

- automated rubric evaluation. *arXiv*, 2026. URL <https://arxiv.org/abs/2602.10367>. preprint only.
- [92] Yang et al. A large language model for electronic health records. *npj Digital Medicine*, 2022. doi: 10.1038/s41746-022-00742-2. URL <https://www.nature.com/articles/s41746-022-00742-2>. published.
- [93] Yang et al. A study of generative large language model for medical research and healthcare. *npj Digital Medicine*, 2023. doi: 10.1038/s41746-023-00958-w. URL <https://www.nature.com/articles/s41746-023-00958-w>. published.
- [94] Zack et al. Coding inequity: Assessing gpt-4’s potential for perpetuating racial and gender biases in healthcare. *medRxiv*, 2023. doi: 10.1101/2023.07.13.23292577. URL <https://doi.org/10.1101/2023.07.13.23292577>. preprint only.
- [95] Zakka et al. Almanac: Retrieval-augmented language models for clinical medicine. *Research Square*, 2023. doi: 10.21203/rs.3.rs-2883198/v1. URL <https://pmc.ncbi.nlm.nih.gov/articles/PMC10187428/>. preprint/pre-publication.
- [96] Zhang et al. Huatuogpt, towards taming language model to be a doctor. *EMNLP Findings/arXiv*, 2023. URL <https://arxiv.org/abs/2305.15075>. published conference version found.
- [97] Zhang et al. Pmc-vqa: Visual instruction tuning for medical visual question answering. *arXiv/Communications Medicine*, 2023. URL <https://arxiv.org/abs/2305.10415>. published journal version found.
- [98] Zhang et al. A generalist vision-language foundation model for diverse biomedical tasks. *Nature Medicine*, 2024. doi: 10.1038/s41591-024-03185-2. URL <https://www.nature.com/articles/s41591-024-03185-2>. published.
- [99] Zuo and Jiang. Medhallbench: A new benchmark for assessing hallucination in medical large language models. *arXiv*, 2024. doi: 10.48550/arXiv.2412.18947. URL <https://arxiv.org/abs/2412.18947>. AAAI-25 Bridge Program / arXiv preprint.
- [100] Zuo et al. Medxpertqa: Benchmarking expert-level medical reasoning and understanding. *PMLR/arXiv*, 2025. URL <https://arxiv.org/abs/2501.18362>. PMLR/openreview/arXiv version.